

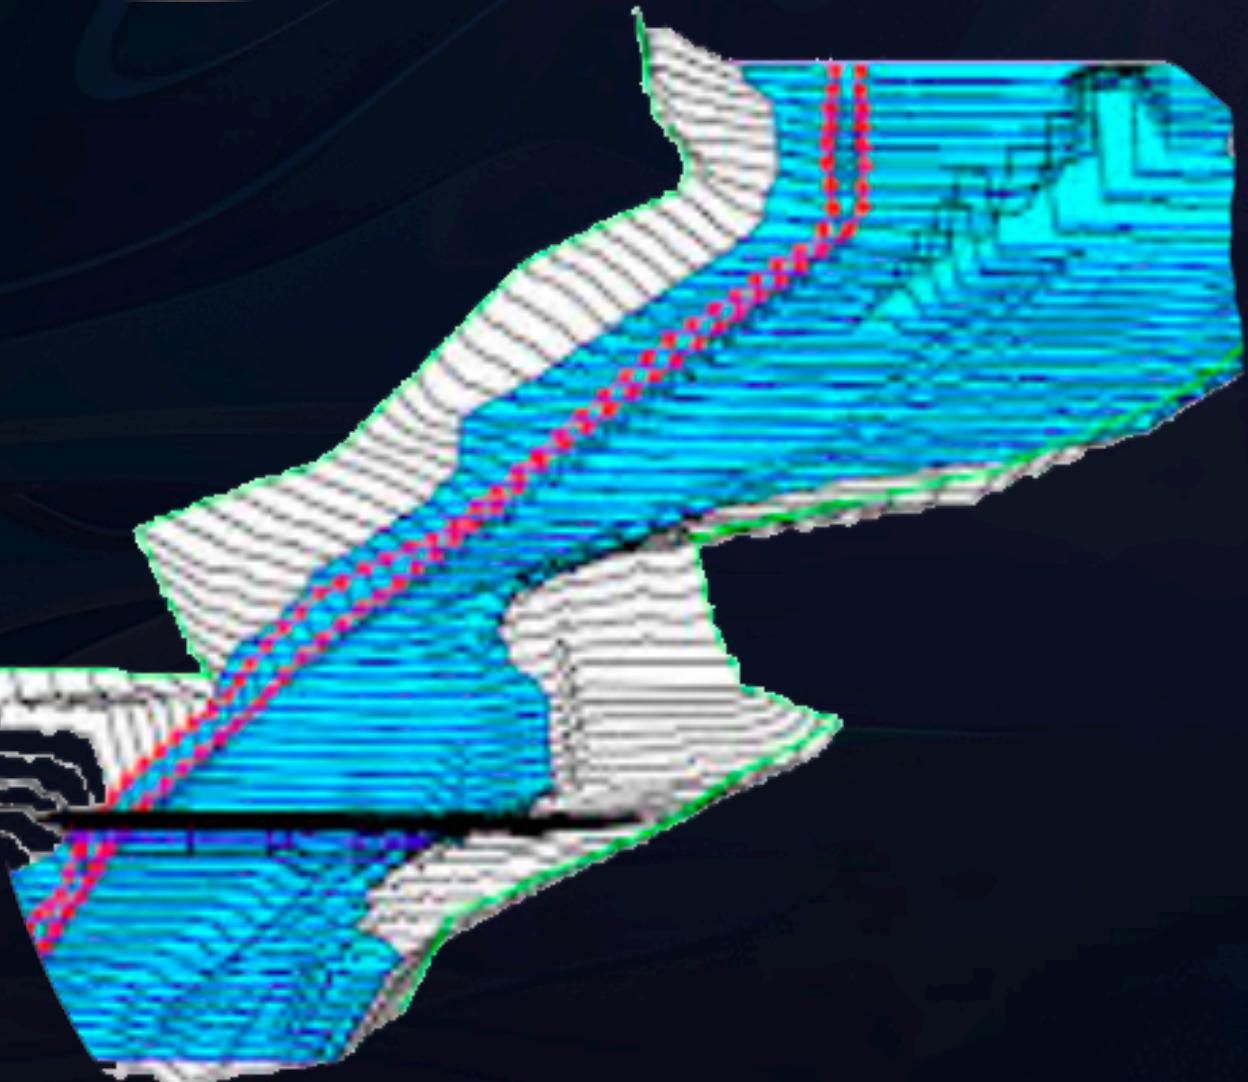
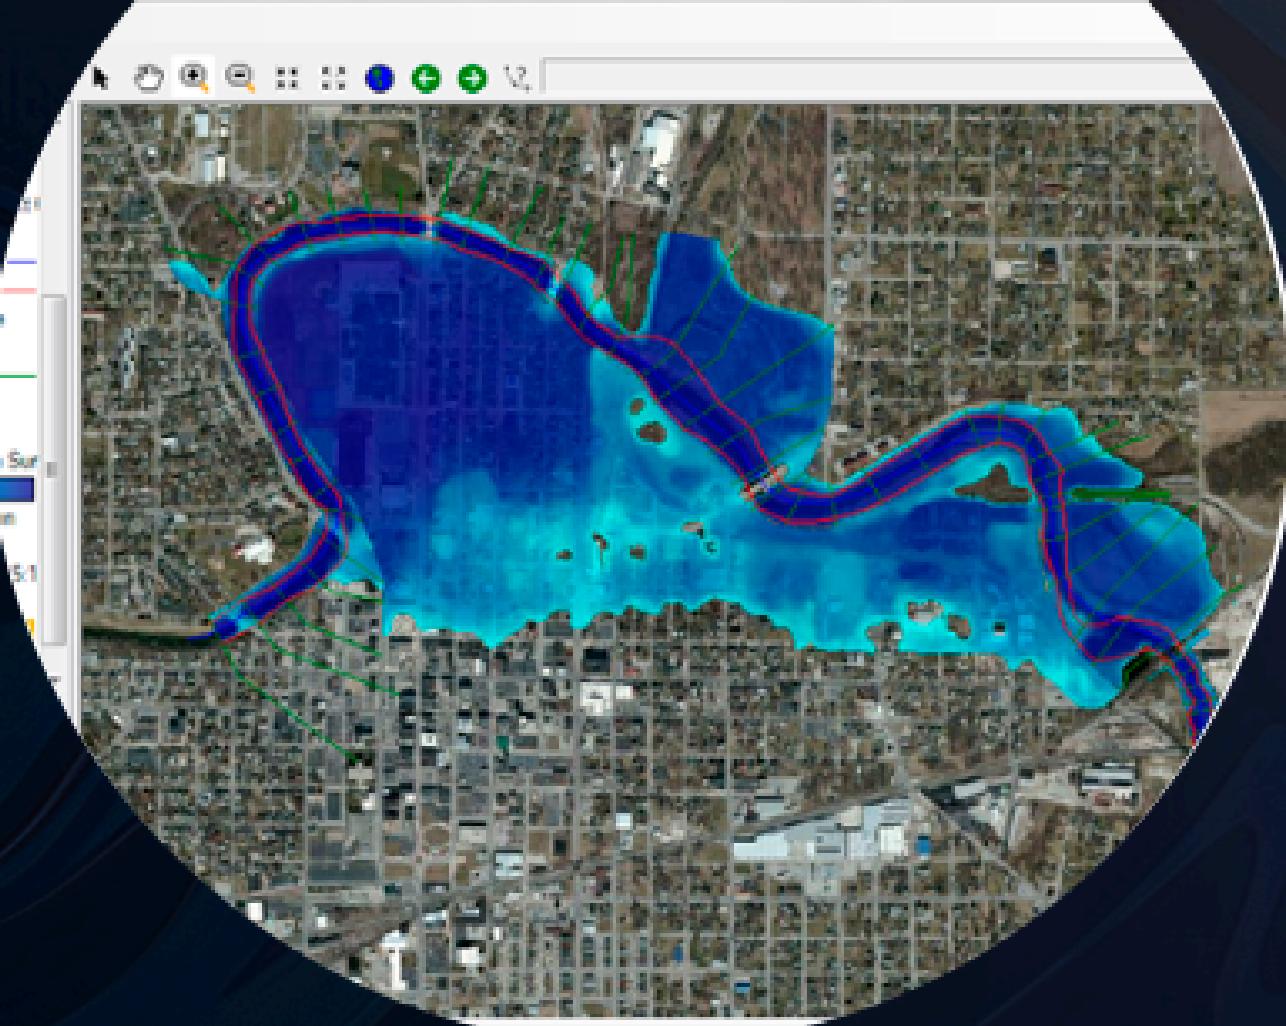
IMPROVING URBAN FLOOD PREDICTION

A HYBRID DEEP LEARNING FRAMEWORK FOR
EXTREME RAINFALL FORECASTING DECISIONS

Qual o problema ?

Enchentes urbanas

- Crescimento dos centros urbanos sem planejamento aumentam áreas suscetíveis a inundações e alagamentos (Canholi, 2015)
- Mudança climática traz aumento das frequência e da magnitude das chuvas intensas (GRÜNDEMANN et al. 2022)
- 8,9 milhões de brasileiros estão em áreas de risco (Brasil, 2024).



Qual a solução ?

RS, 2024



Valencia, 2024

Qual a solução ?

Petrópolis, 2023



SP, 2024

Qual a solução ?

SP, 2024



Alemanha, 2021

Qual a solução ?

Medidas Estruturais

- Remoção de população em áreas de riscos
- Estruturas de mitigação
- Alterações dos padrões de urbanização

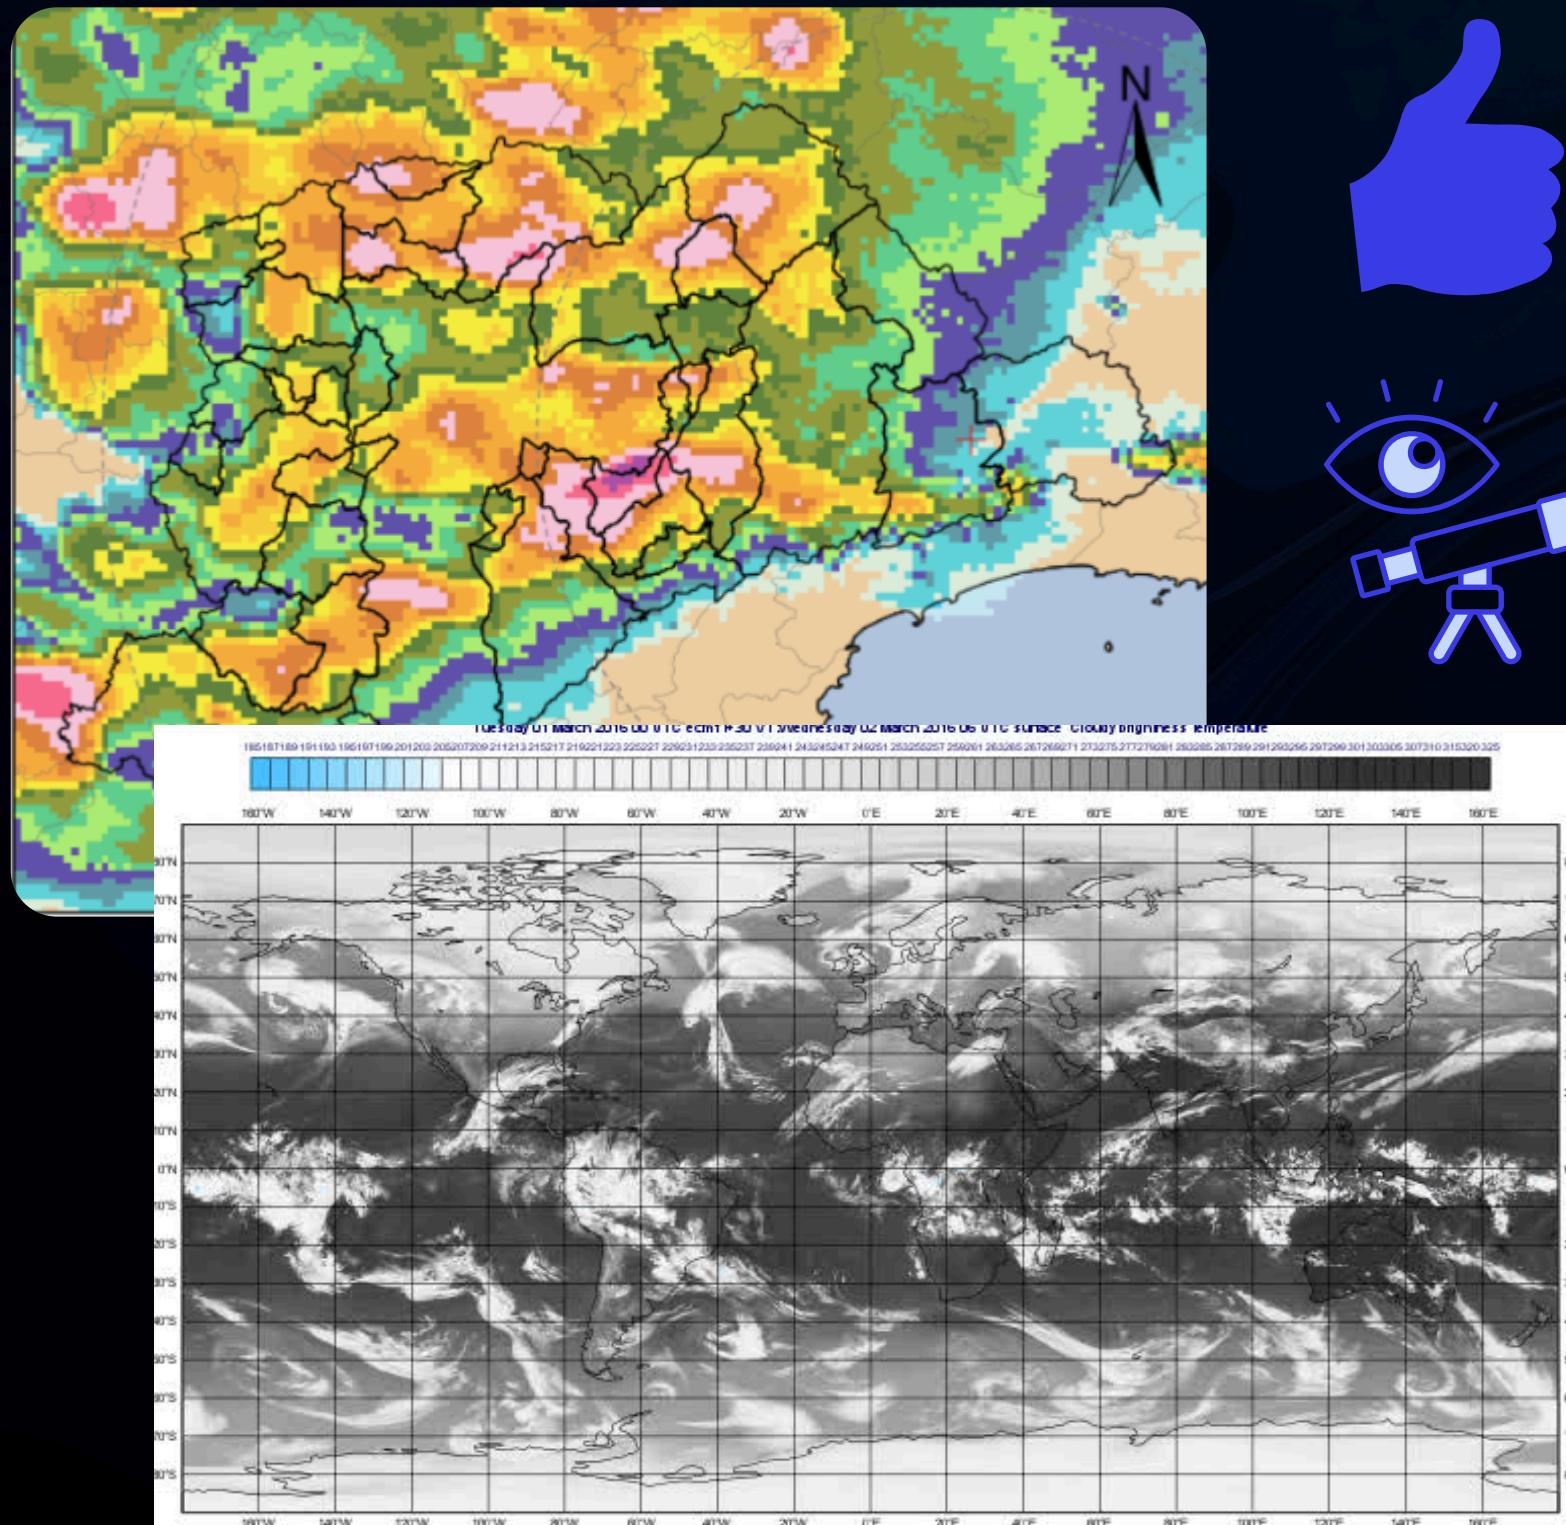


Medidas não-estruturais

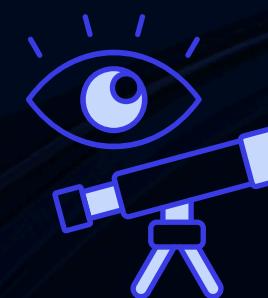
- Planos diretores de drenagem integrados
- Sistemas de previsão e alerta
- Políticas Públicas



Sistemas de Previsão e Alerta



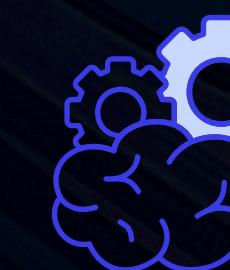
Melhorar assertividade



Antecipação



Plano de Ação Emergencial

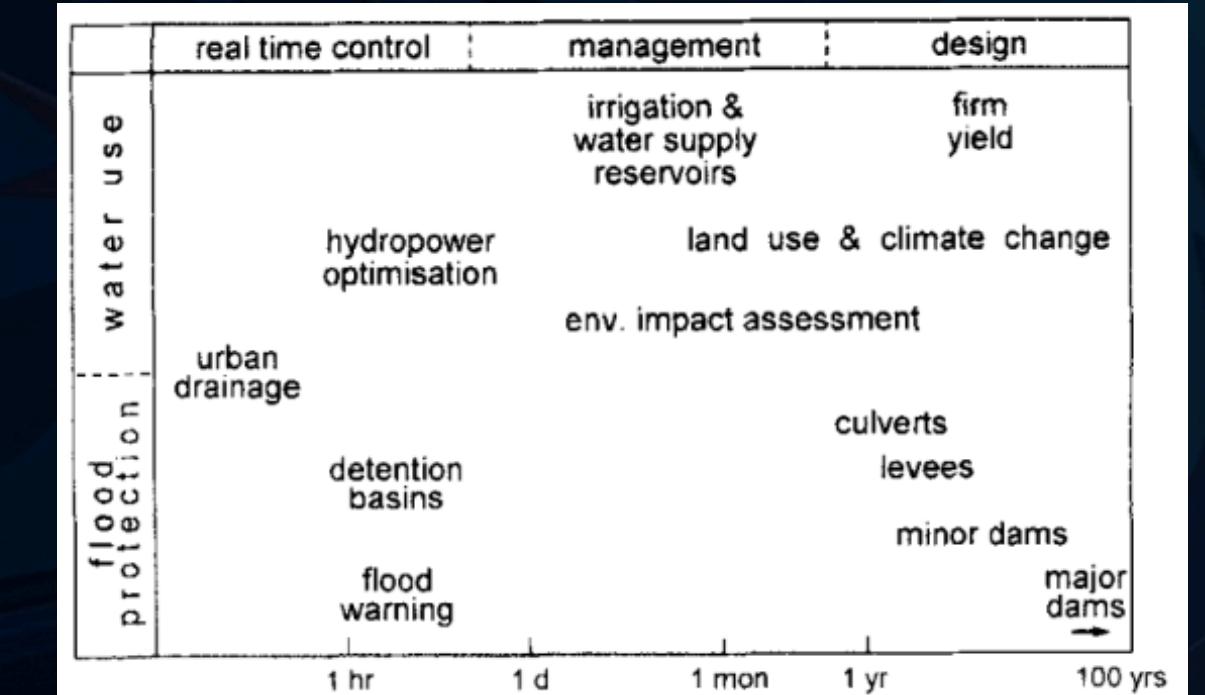


Adaptação e Preparação

Eventos de Chuvas Intensas



Sistemas Complexos



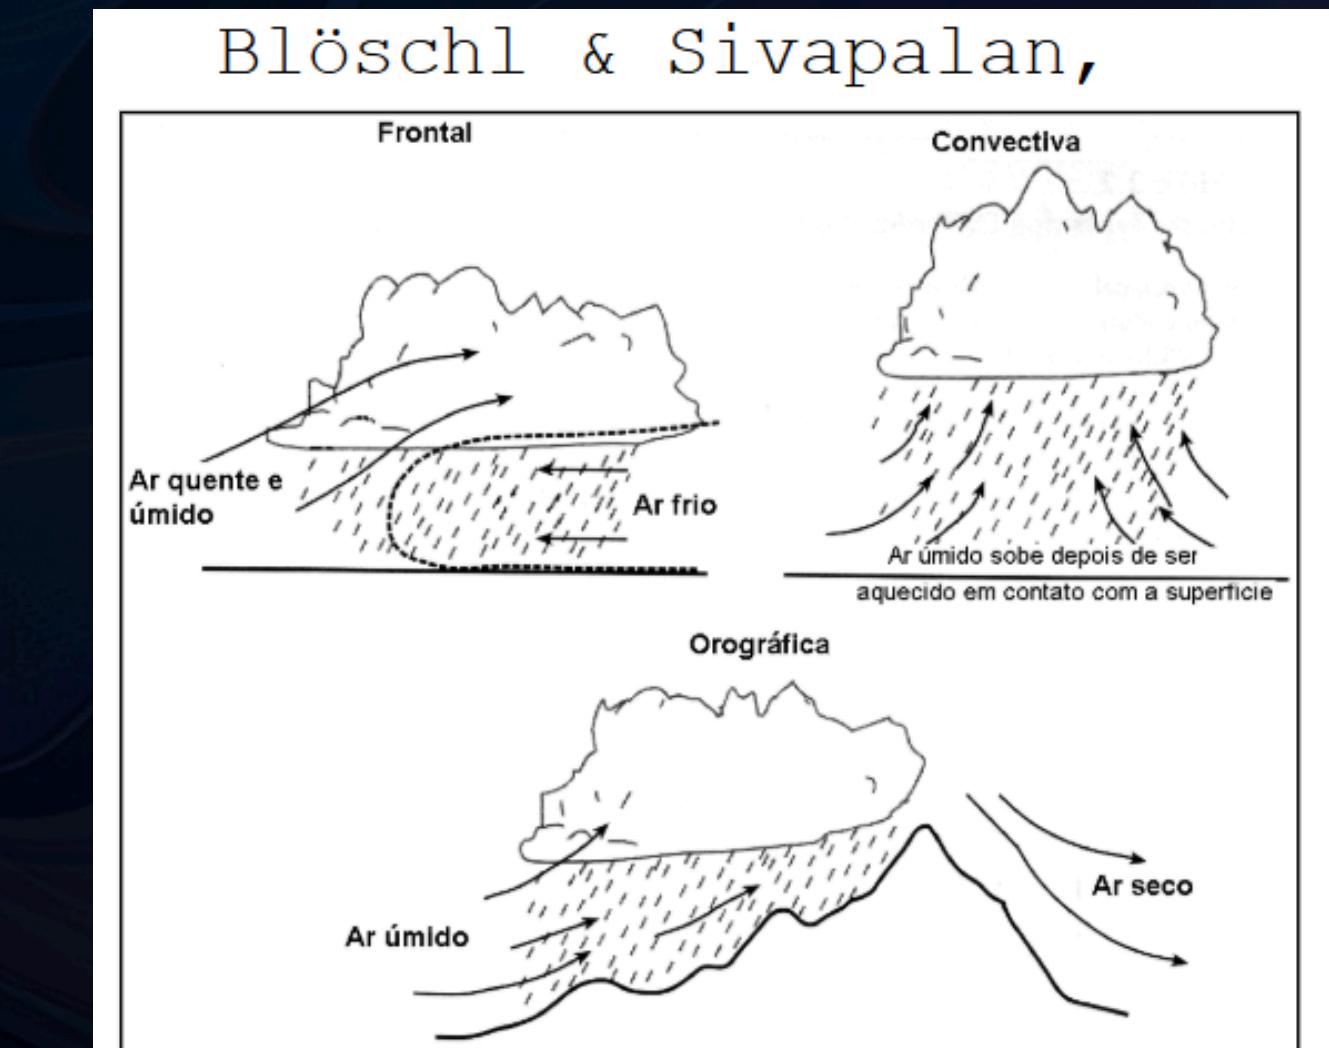
Não lineares



Diferentes escalas de resposta hidrológica



Antecipação em função da resposta do sistema hidrológico



Importância da união AmbMeca

Unidos pelo futuro

No nosso campus, somos dois cursos, mas com um só propósito: transformar o mundo. As duas engenharias compartilham mais do que o espaço: compartilham valores, visão e potencial. Enquanto uma entende e protege a natureza, a outra desenvolve soluções inteligentes e sustentáveis. Juntos, temos tudo para inovar, colaborar e criar um futuro onde a tecnologia e o meio ambiente caminham lado a lado. Porque a verdadeira mudança começa com união, consciência e ação.

"Se não cuidarmos do nosso planeta, ele poderá morrer em menos de 100 anos."
— Stephen Hawking



Quem sou eu?

Estudante do 9º termo de ECA no ICTS

Colaborador Bolsista da =LI~~CE~~CE=

AI Research Colaborator na  recod.ai

CEO da hair'U



O que veremos hoje?

O que são Séries temporais?

Entendendo o Problema dos eventos extremos

Topologias de séries estatísticas e de ML

Topologias de Deep Learning para séries

Como estou resolvendo o problema?

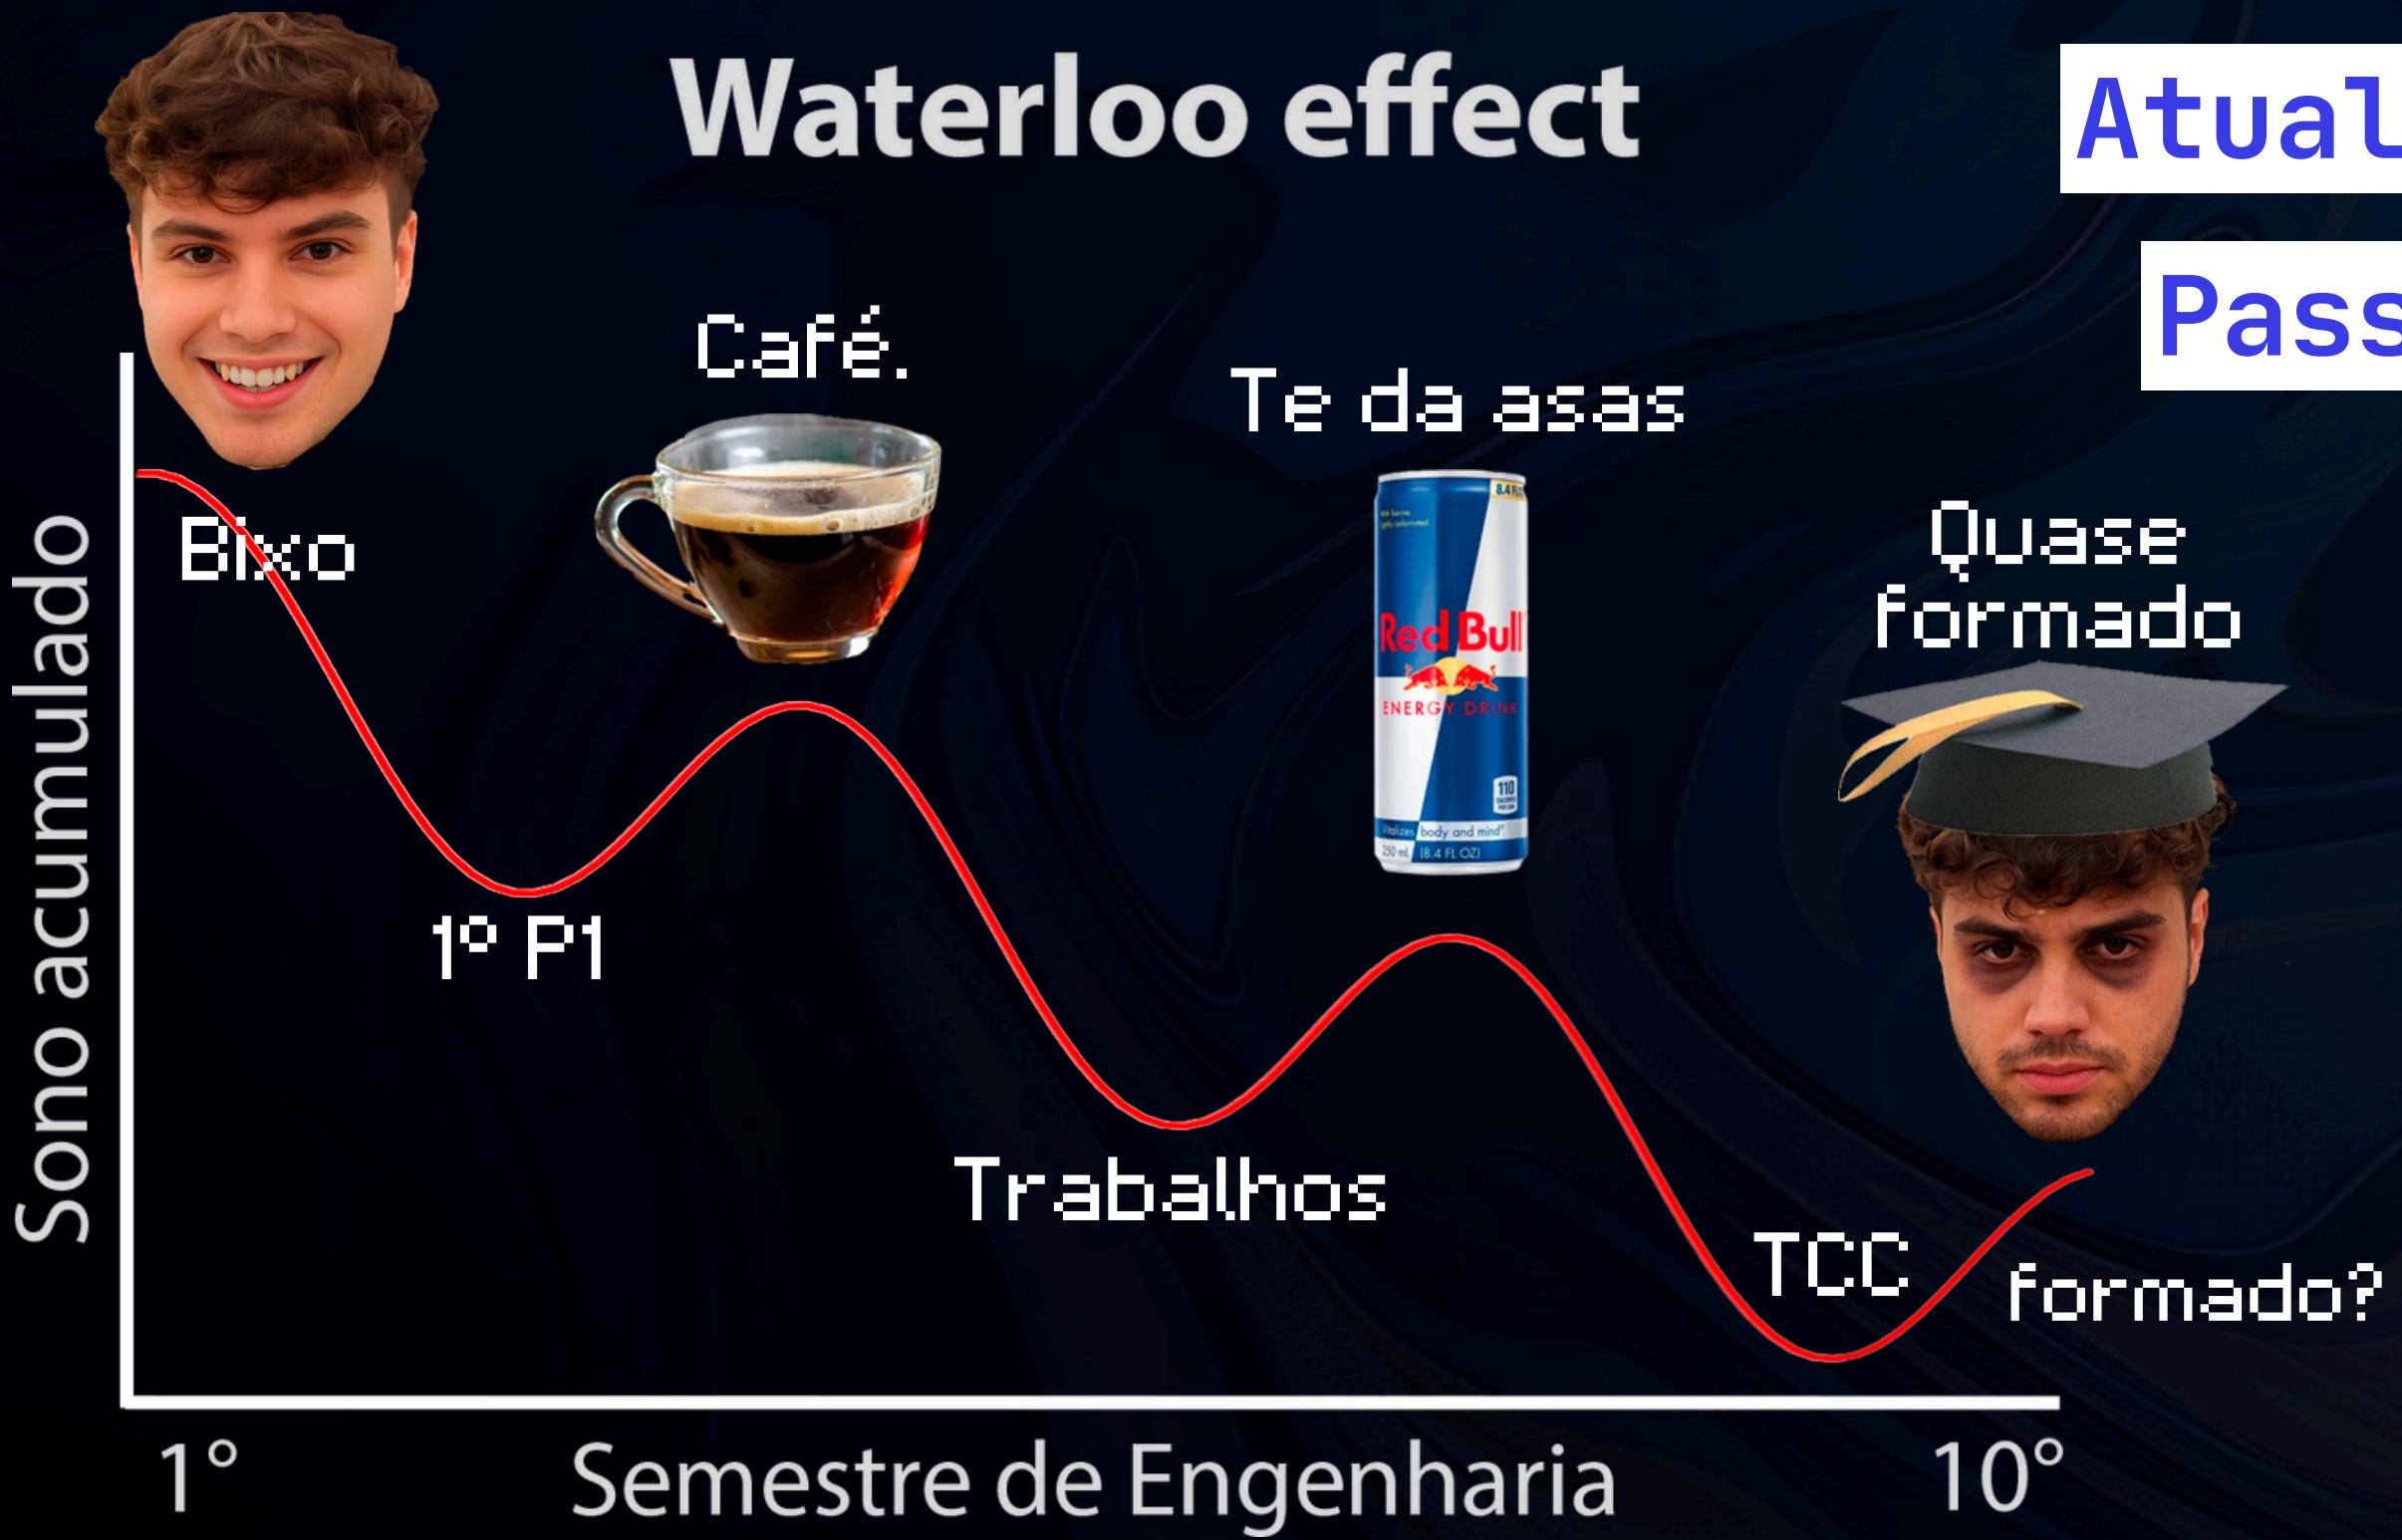
Embedding e Ensemble Learning

Funções de Custo e suas customizações

Resultados e Projetos Futuros



O que são series temporais?



Atual depende do passado

Passado prevê o futuro?

Dependente do tempo



Como ficaria um dataset ?

Considerando
variáveis de 0 a 1
para facilitar

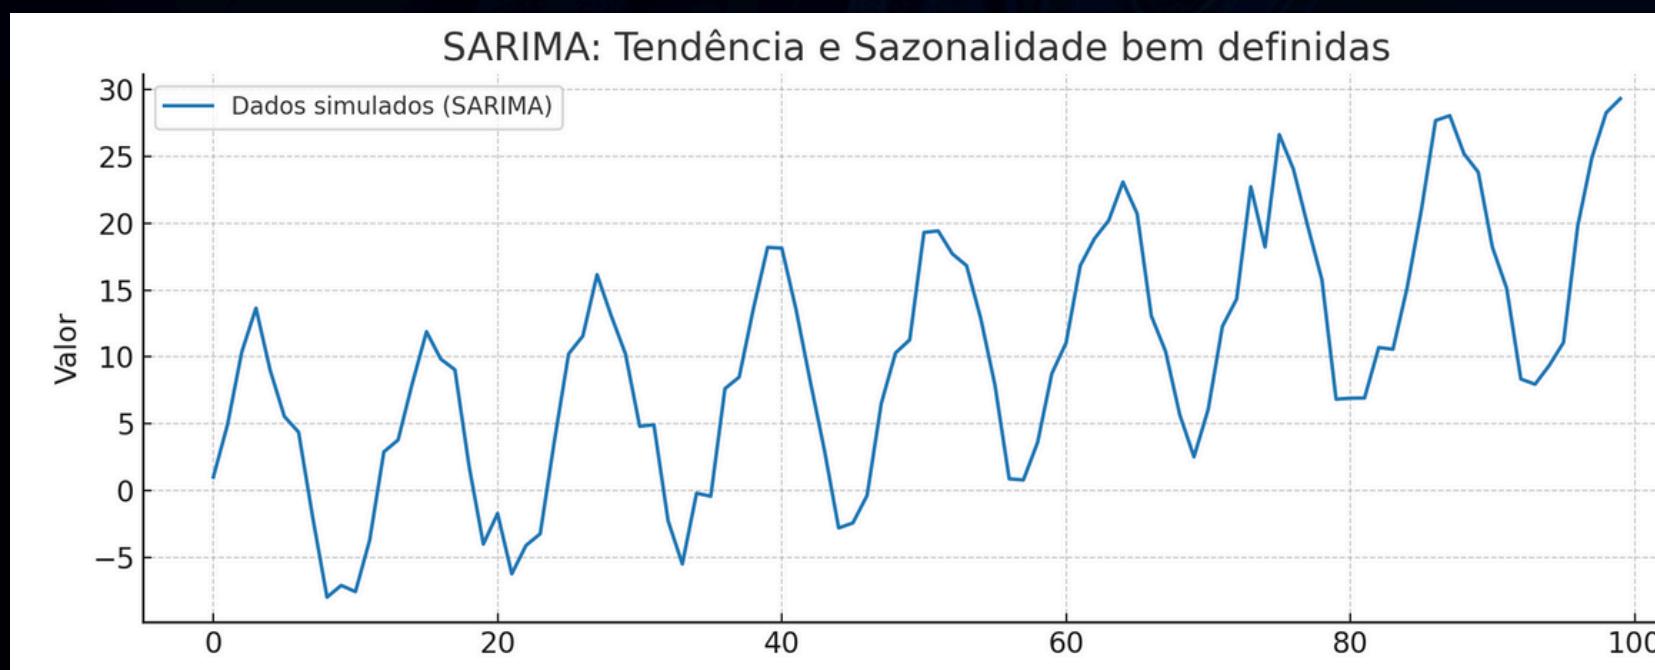
Tempo	X ou variáveis	y ou target	
Semestre	Estresse	cafeina	Sono
1	0.01	0.01	1
3	0.35	0.5	0.7
5	0.65	0.8	0.5
7	0.78	0.9	0.35
9	0.95	1	0.2
11	1	1.5	0.02

Ao deixar de considerar semestres percebemos que
não conseguimos capturar bem as tendências!

Métodos estatísticos e ML

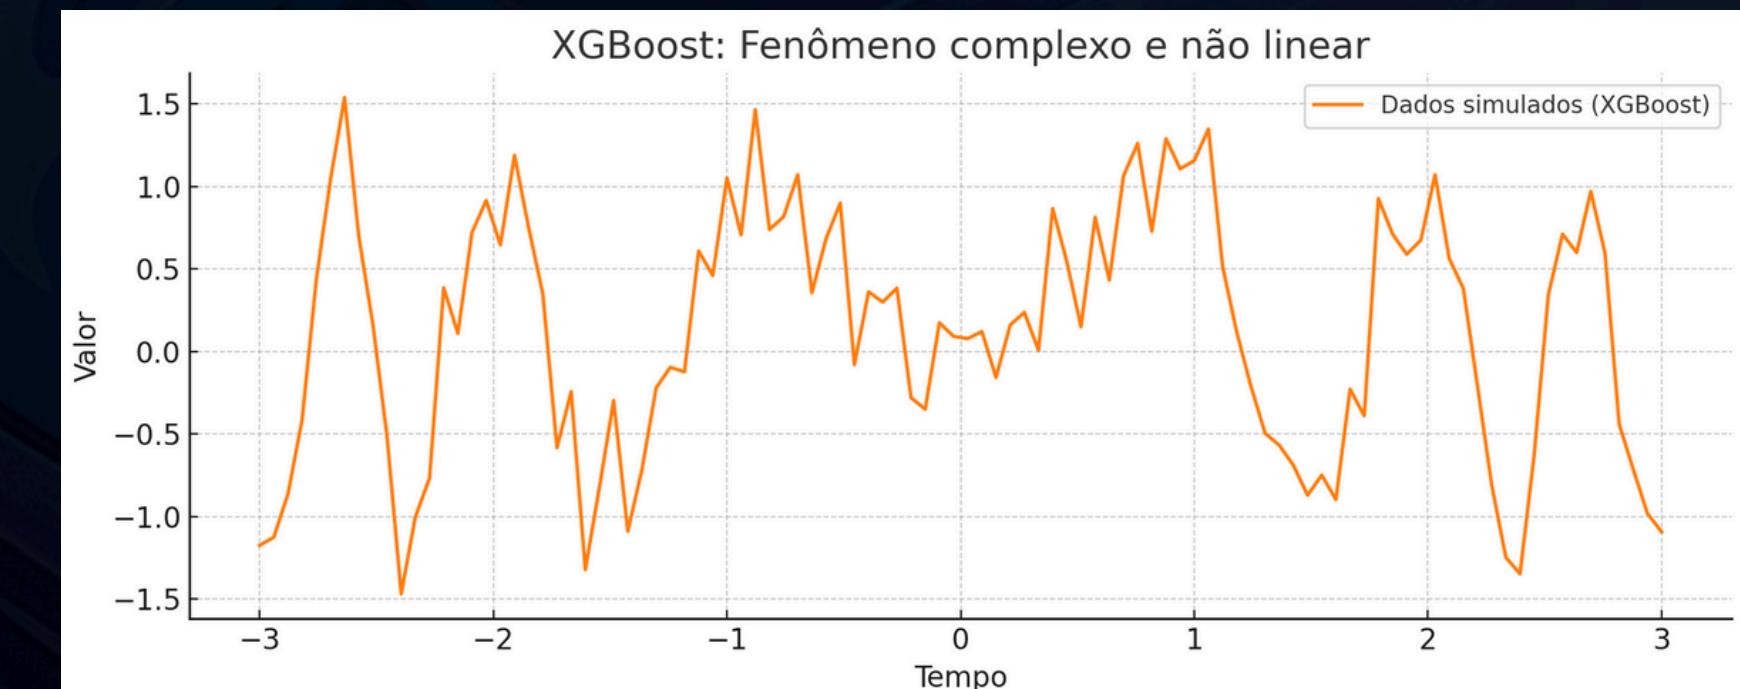
Modelos Estatísticos Arima e Sarima

eficazes para tendências e sazonalidades bem definidas.



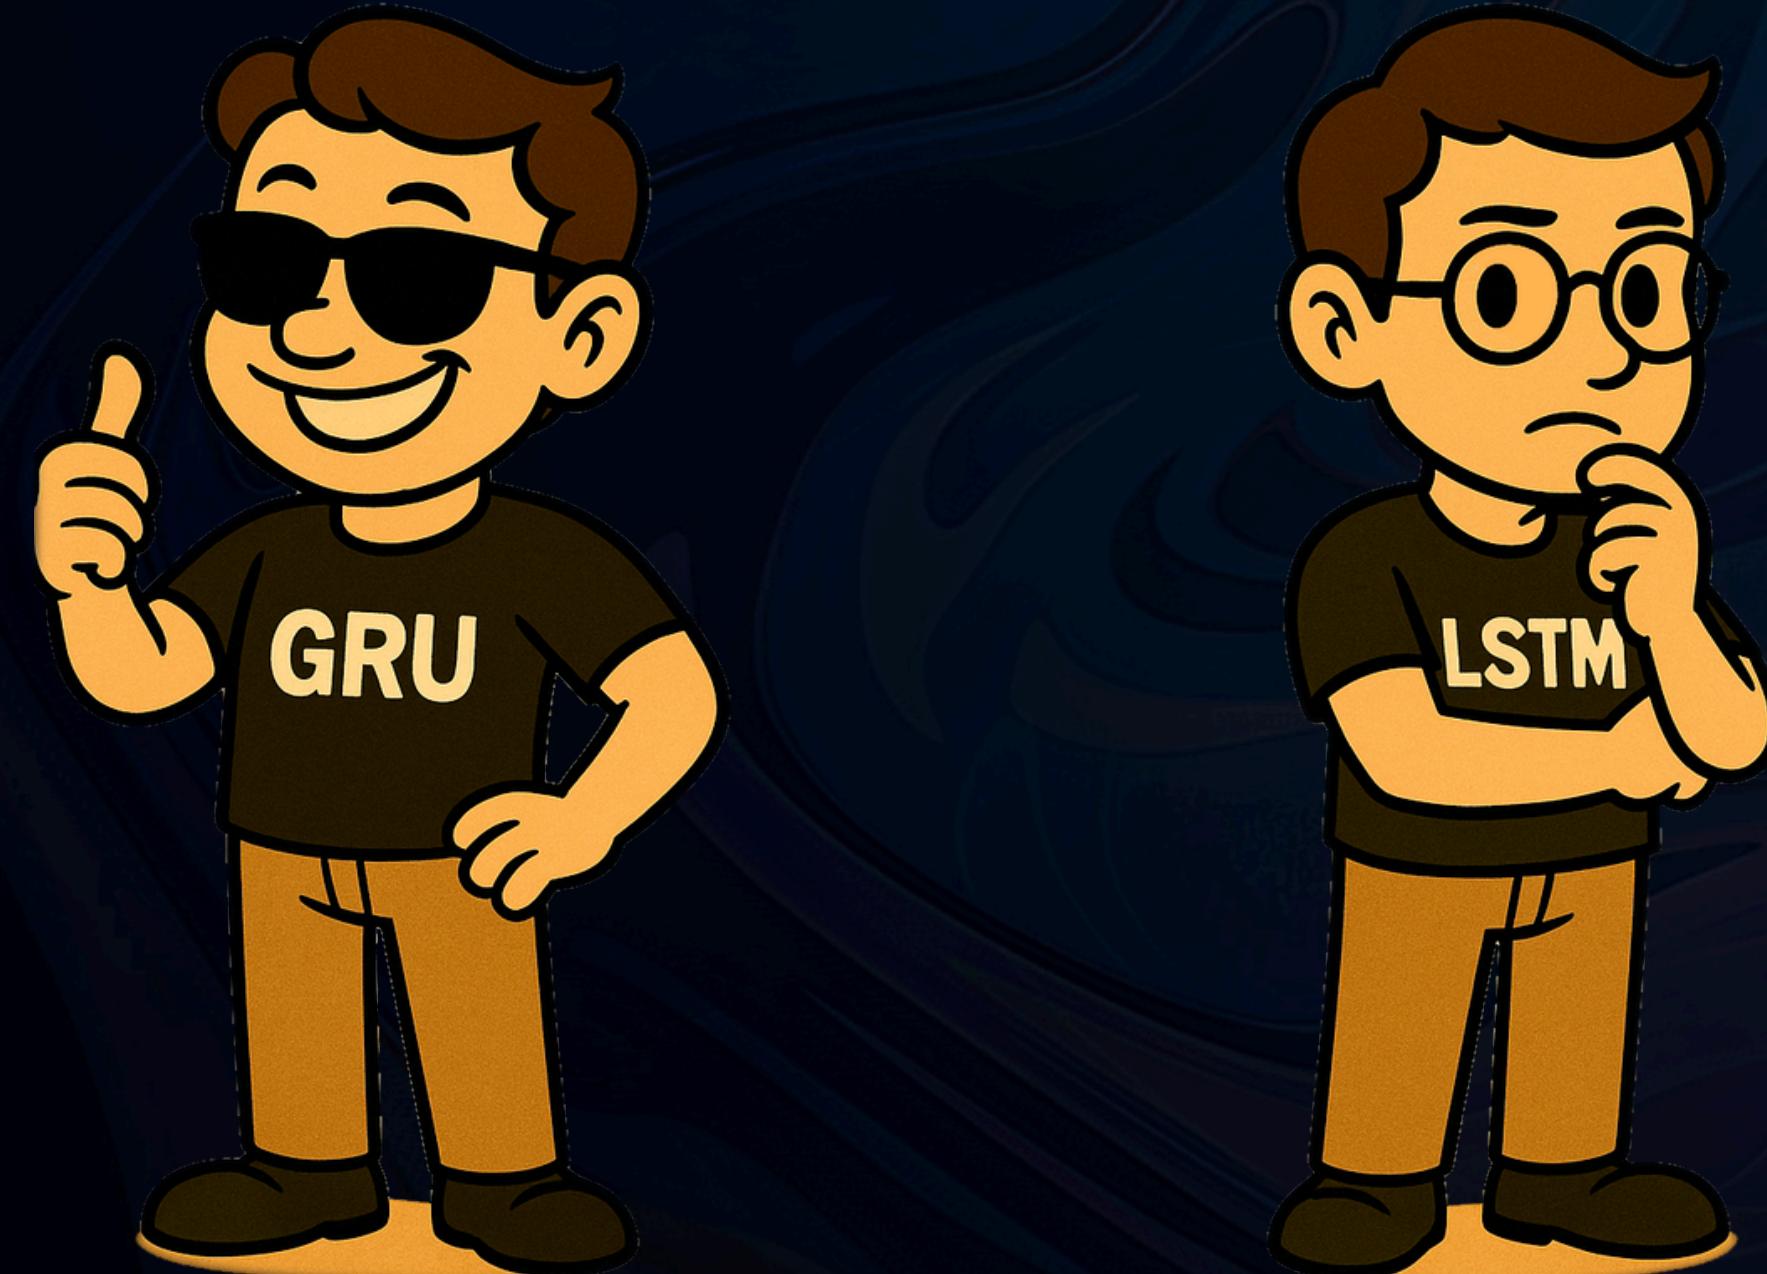
Machine Learning XGBoost

ideal para lidar com fenômenos complexos e não lineares.



Métodos de deep learning

GRU e LSTM A história de dois gêmeos separados na maternidade



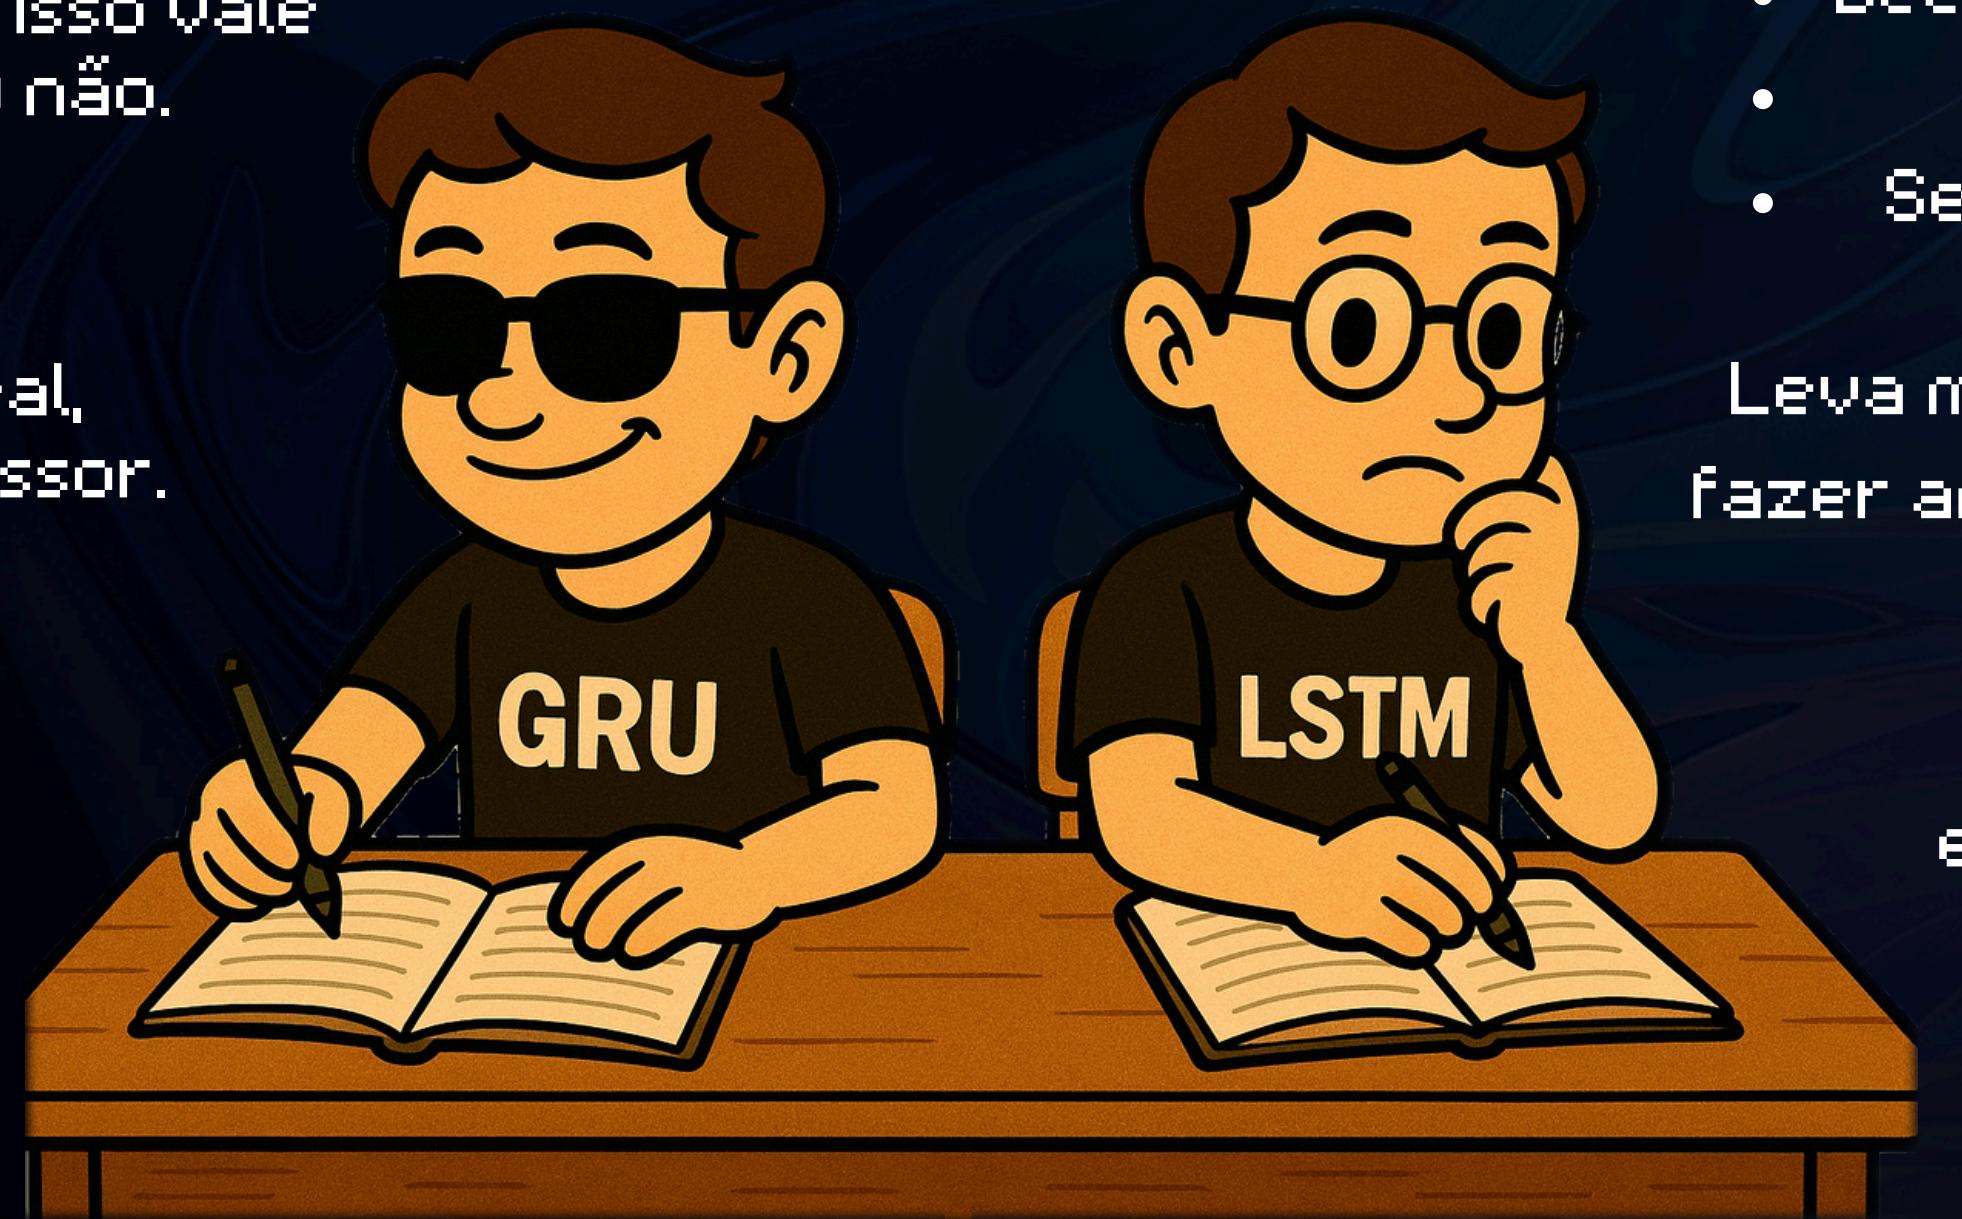
GRU o aluno esperto e direto

Anota o essencial, apagando o que não importa e guardando o que parece útil.

Usa um método rápido: "isso vale lembrar?" → Sim ou não.

Faz isso em tempo real, acompanhando o professor.

✓ Rápido, eficiente, mas às vezes pode esquecer nuances.



LSTM o aluno metódico

Tem um caderno bem organizado.

Para cada nova informação ele:

- Decide se apaga (esquece),
- Se guarda, e
- Se usa agora ou depois.

Leva mais tempo, mas costuma fazer anotações mais completas.

✓ Mais cuidadoso e esquece menos nuances, porém mais lento.

Comparação com ML E estatisticos

Método	Capta Sazonalidade	Capta Não Linearidade	Capta Memória Longa	Ideal Para
SARIMA	<input checked="" type="checkbox"/> Sim	<input type="checkbox"/> Não	<input type="checkbox"/> Não	Séries simples e cíclicas
XGBoost	<input type="checkbox"/> Não	<input checked="" type="checkbox"/> Sim	<input type="checkbox"/> Não	Dados tabulares complexos
LSTM	<input checked="" type="checkbox"/> Sim	<input checked="" type="checkbox"/> Sim	<input checked="" type="checkbox"/> Sim	Séries longas e ruidosas
GRU	<input checked="" type="checkbox"/> Sim	<input checked="" type="checkbox"/> Sim	<input checked="" type="checkbox"/> Moderado	Séries com menor custo

Em outro multiverso: BI-GRU e BI-LSTM A história de dois gêmeos separados na maternidade

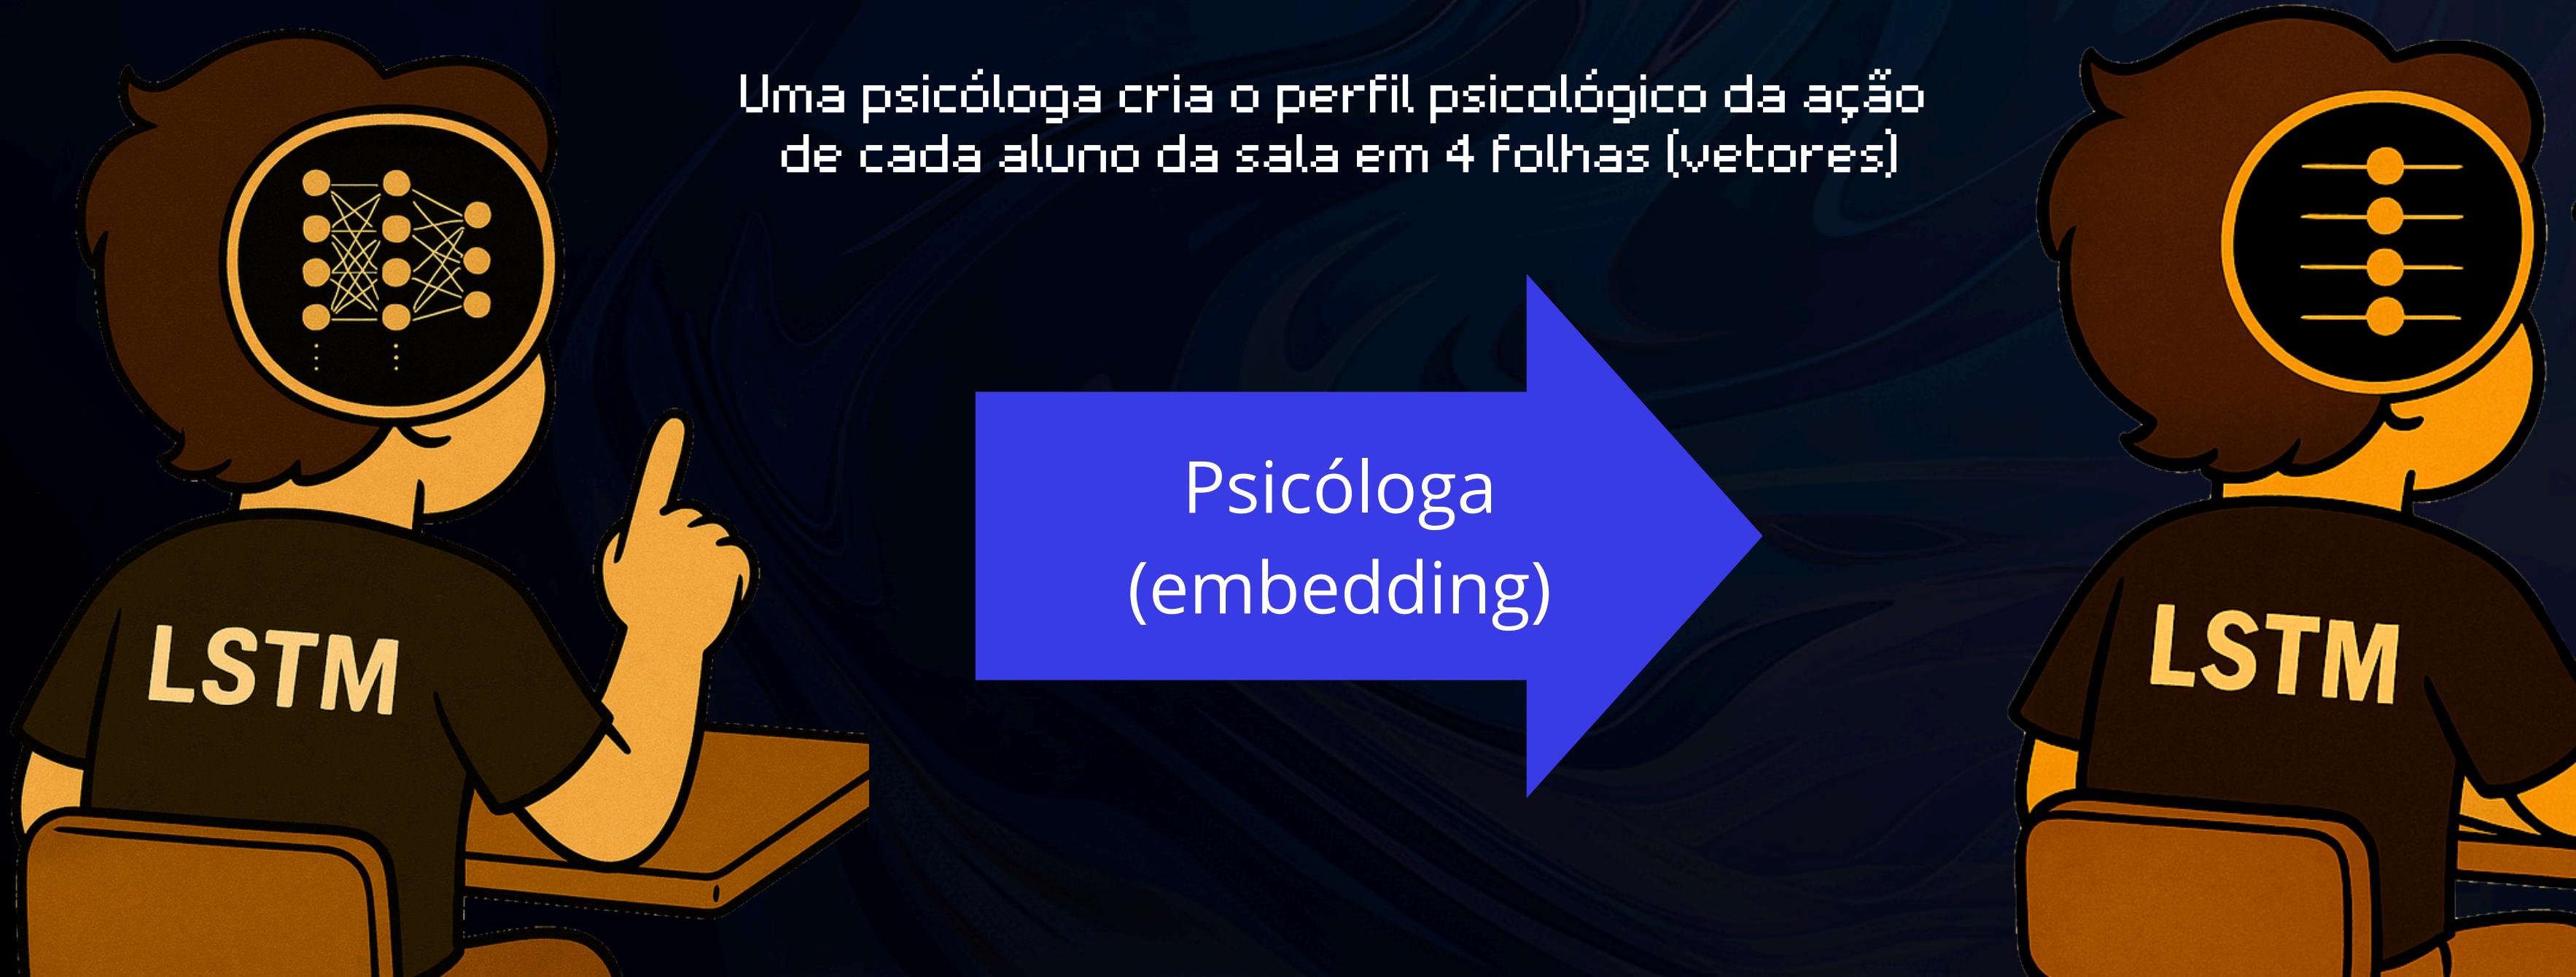
entendem melhor porque
escutam a aula duas vezes

Anotam enquanto a aula acontece
Uma vez do passado pro futuro

Mas depois revêm a gravação
Outra vez do futuro pro passado



Entendendo o Embedding

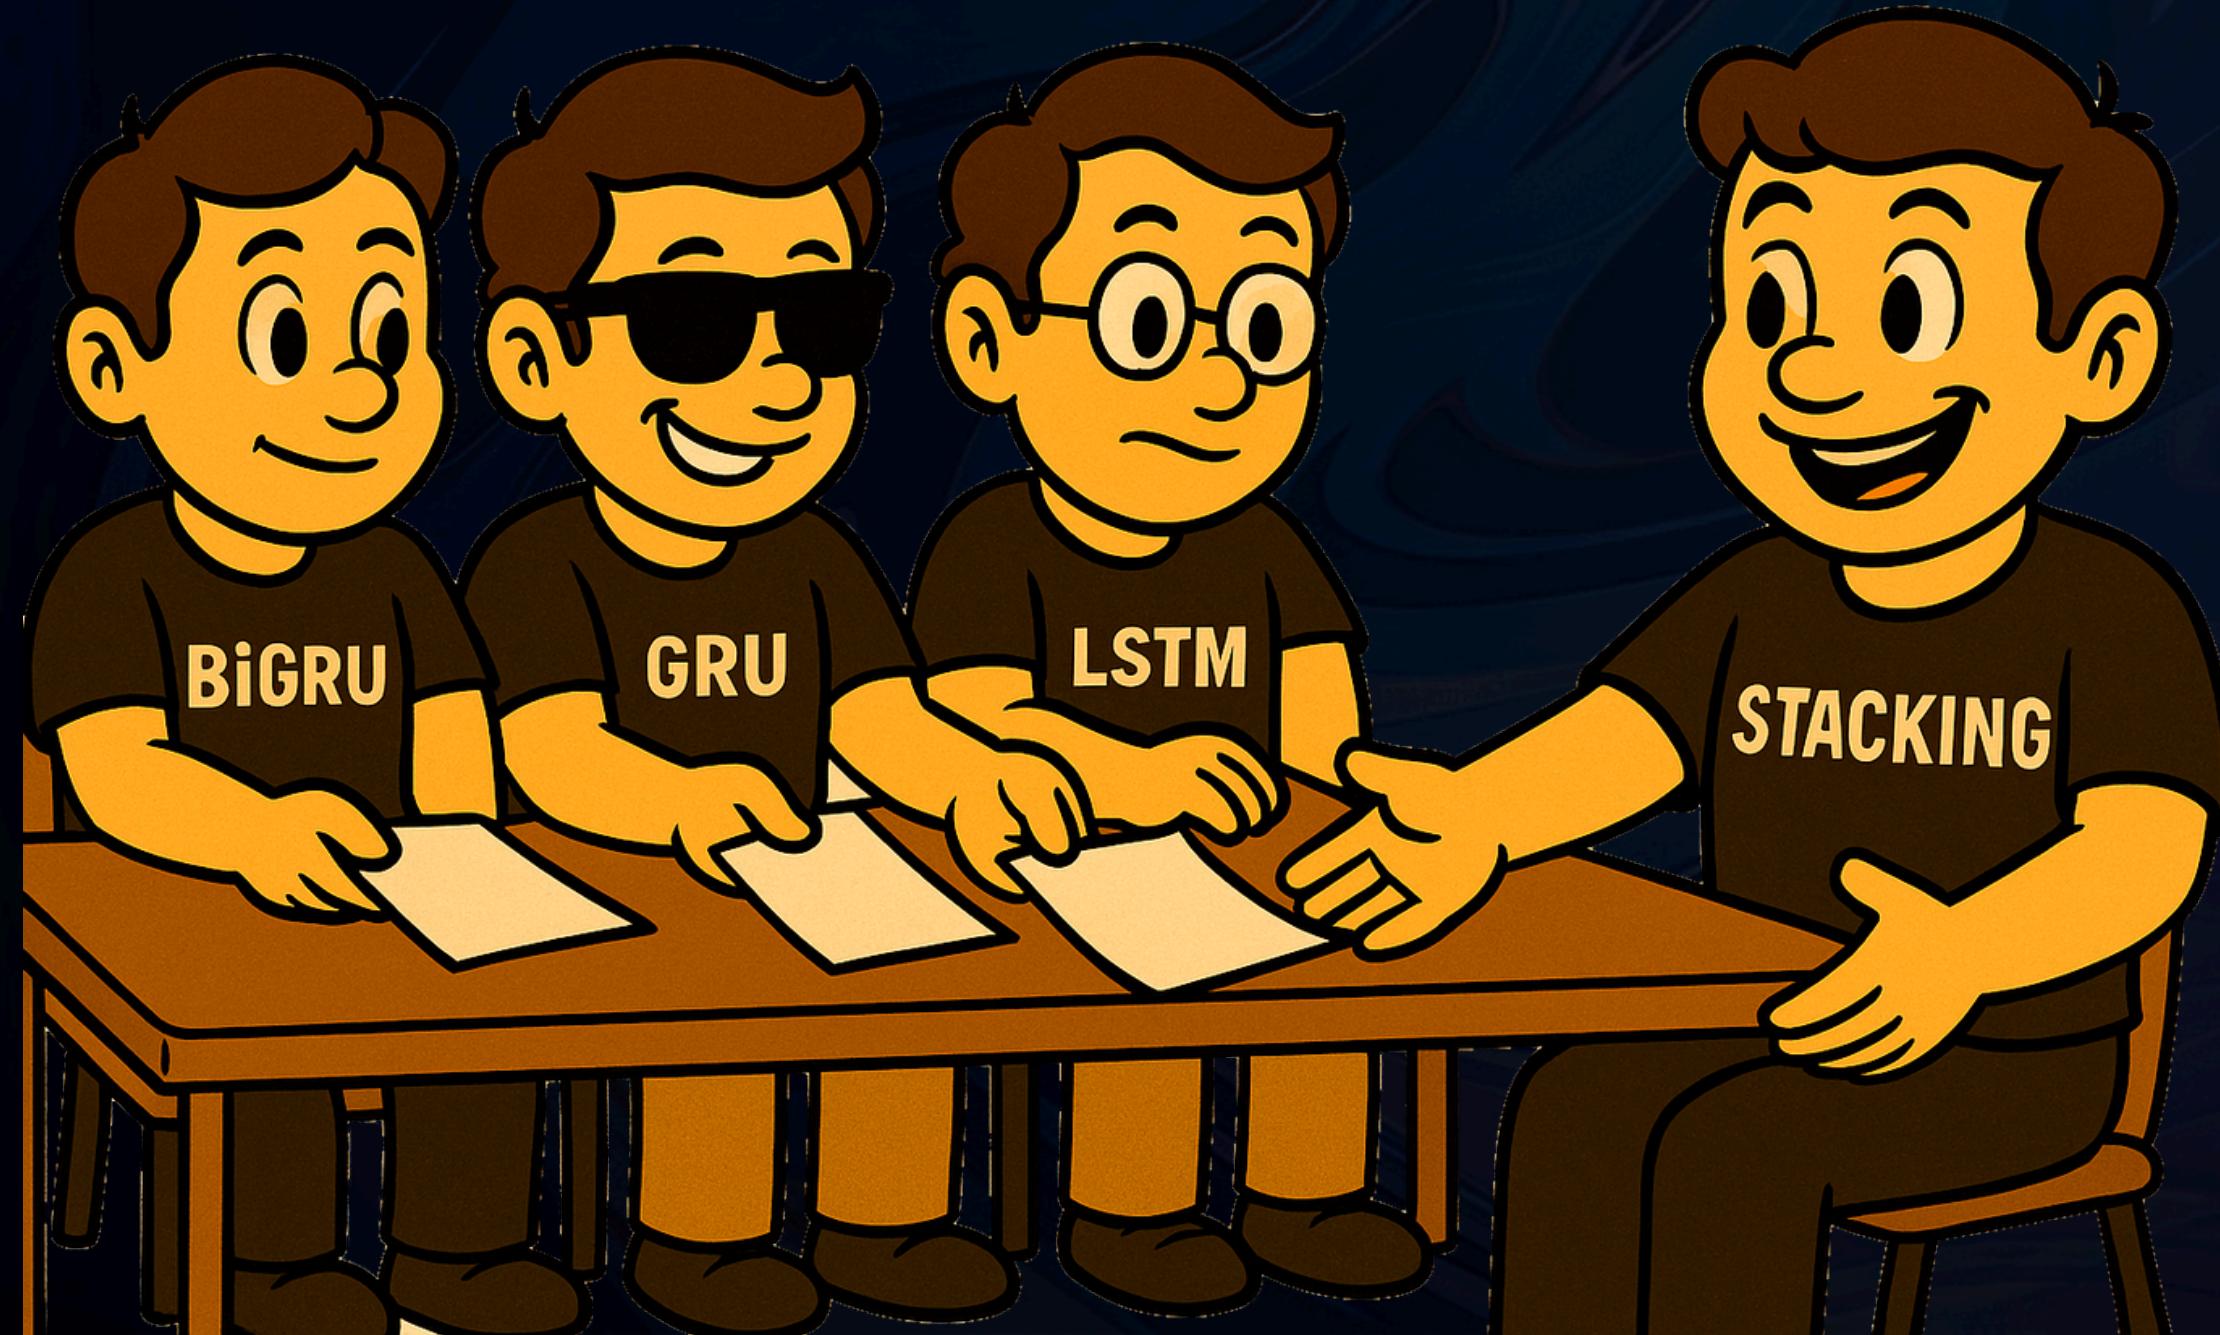


Uma psicóloga cria o perfil psicológico da ação de cada aluno da sala em 4 folhas (vetores)

Psicóloga
(embedding)

Entendendo o Stacking

Os alunos entregam as suas folhas para o senhor stacking, que pega as melhores qualidades de cada um e decide qual usar no tempo.



Custom Loss, esse é o segredo !

O senhor stacking usa um critério de avaliação diferente para classificar seus alunos, pensando em achar o melhor potencial deles em resolver o problema ao invés de fazer uma média comum.

Essa critério funciona dando peso maior para as perguntas mais difíceis. Se o aluno erra uma pergunta fácil, tudo bem. Mas se ele erra uma questão crítica, perde muito mais ponto.

As questões críticas são os eventos extremos (acima de 38mm)



Custom Loss, esse é o segredo !

Matematicamente temos :

$$\text{loss} = \text{diff} \cdot (1 + \alpha \cdot \text{mask})$$

o qual $\text{diff} = |\text{ytrue} - \text{ypred}|$

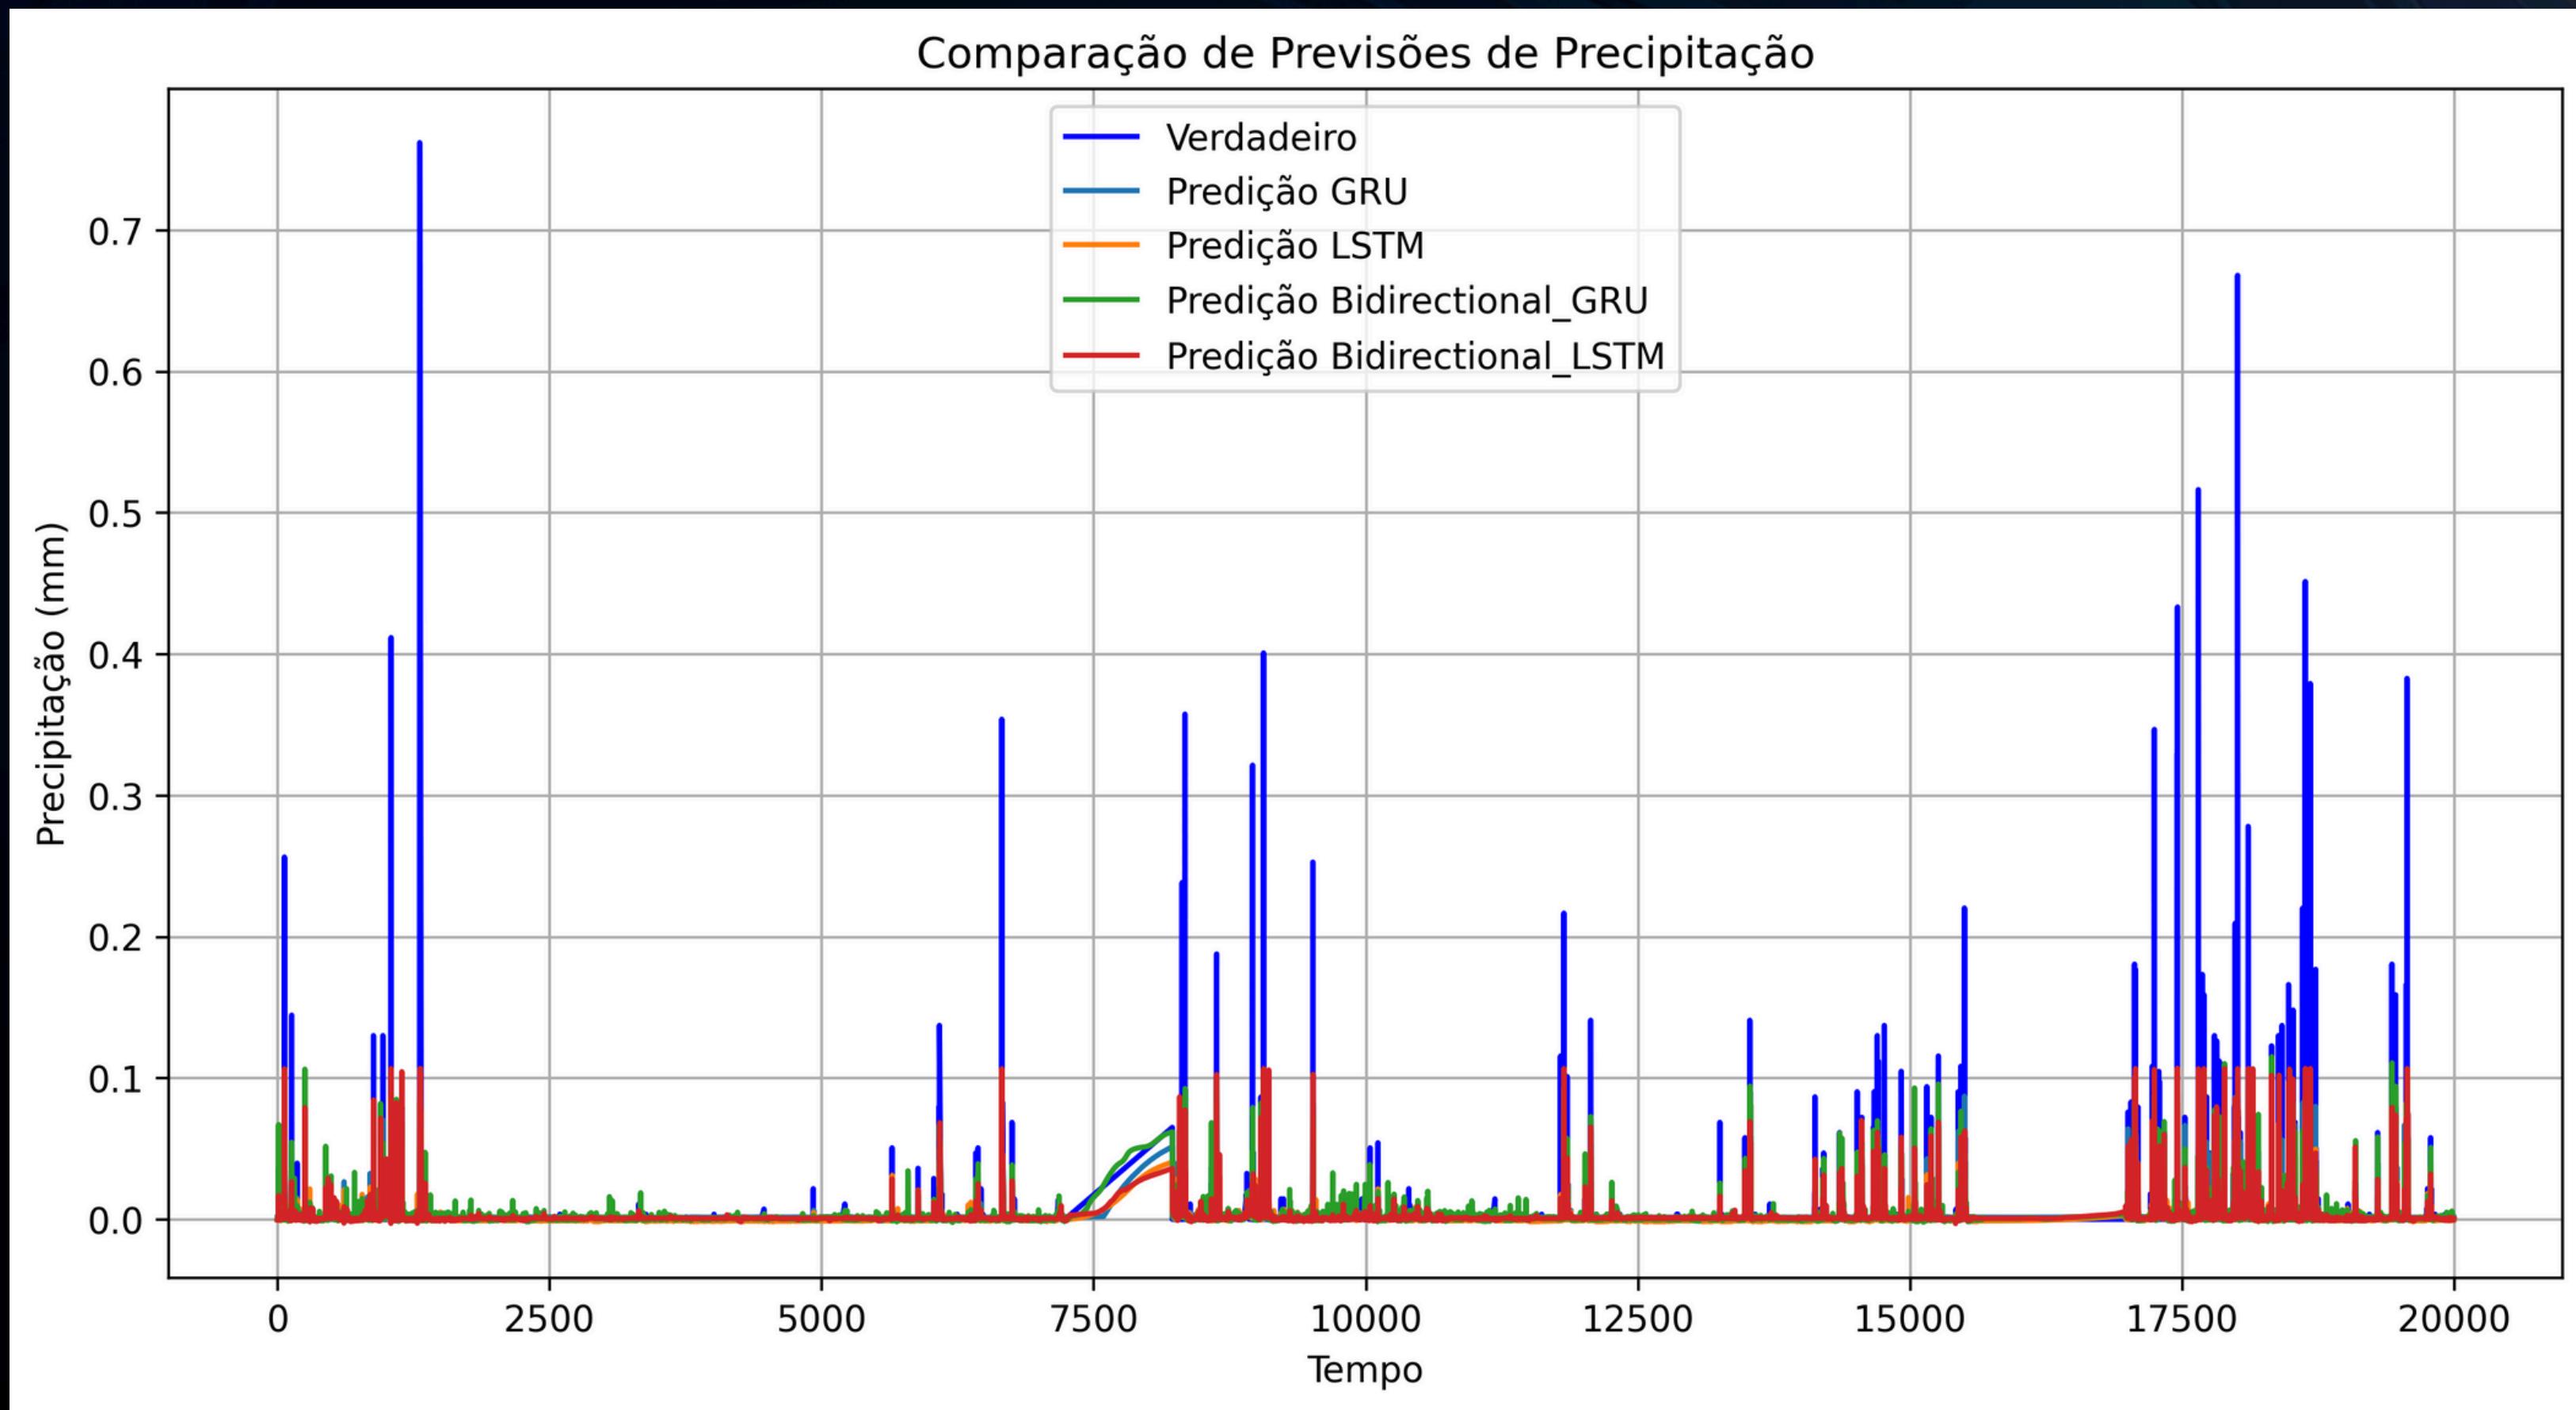
α = peso na correção

Threshold = 38mm define o mask

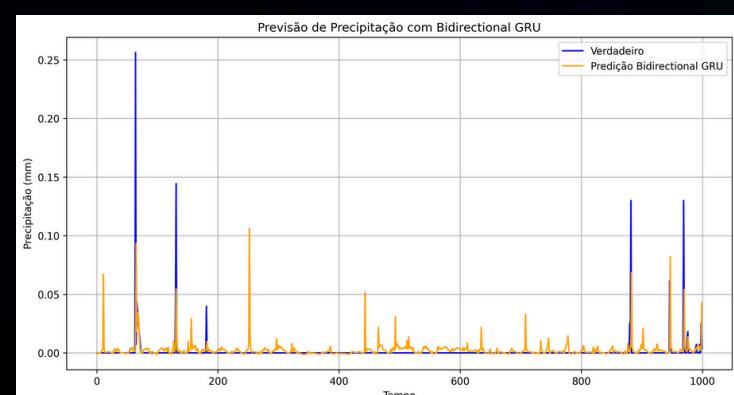
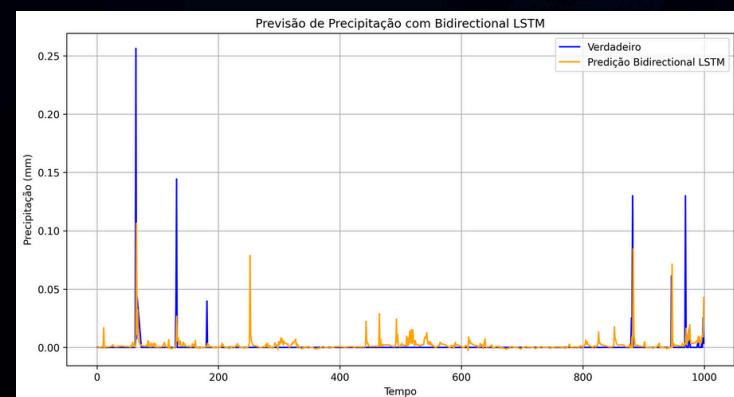
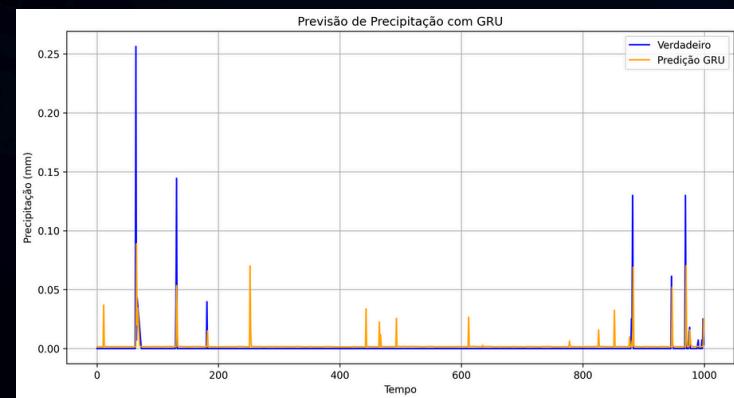
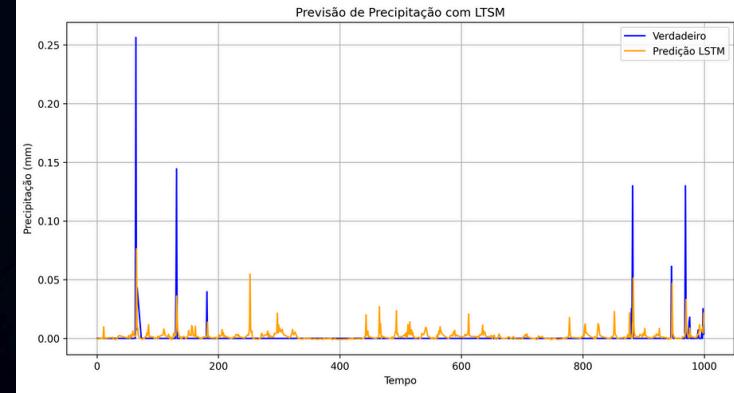
mask = chuva extrema (0 ou 1)



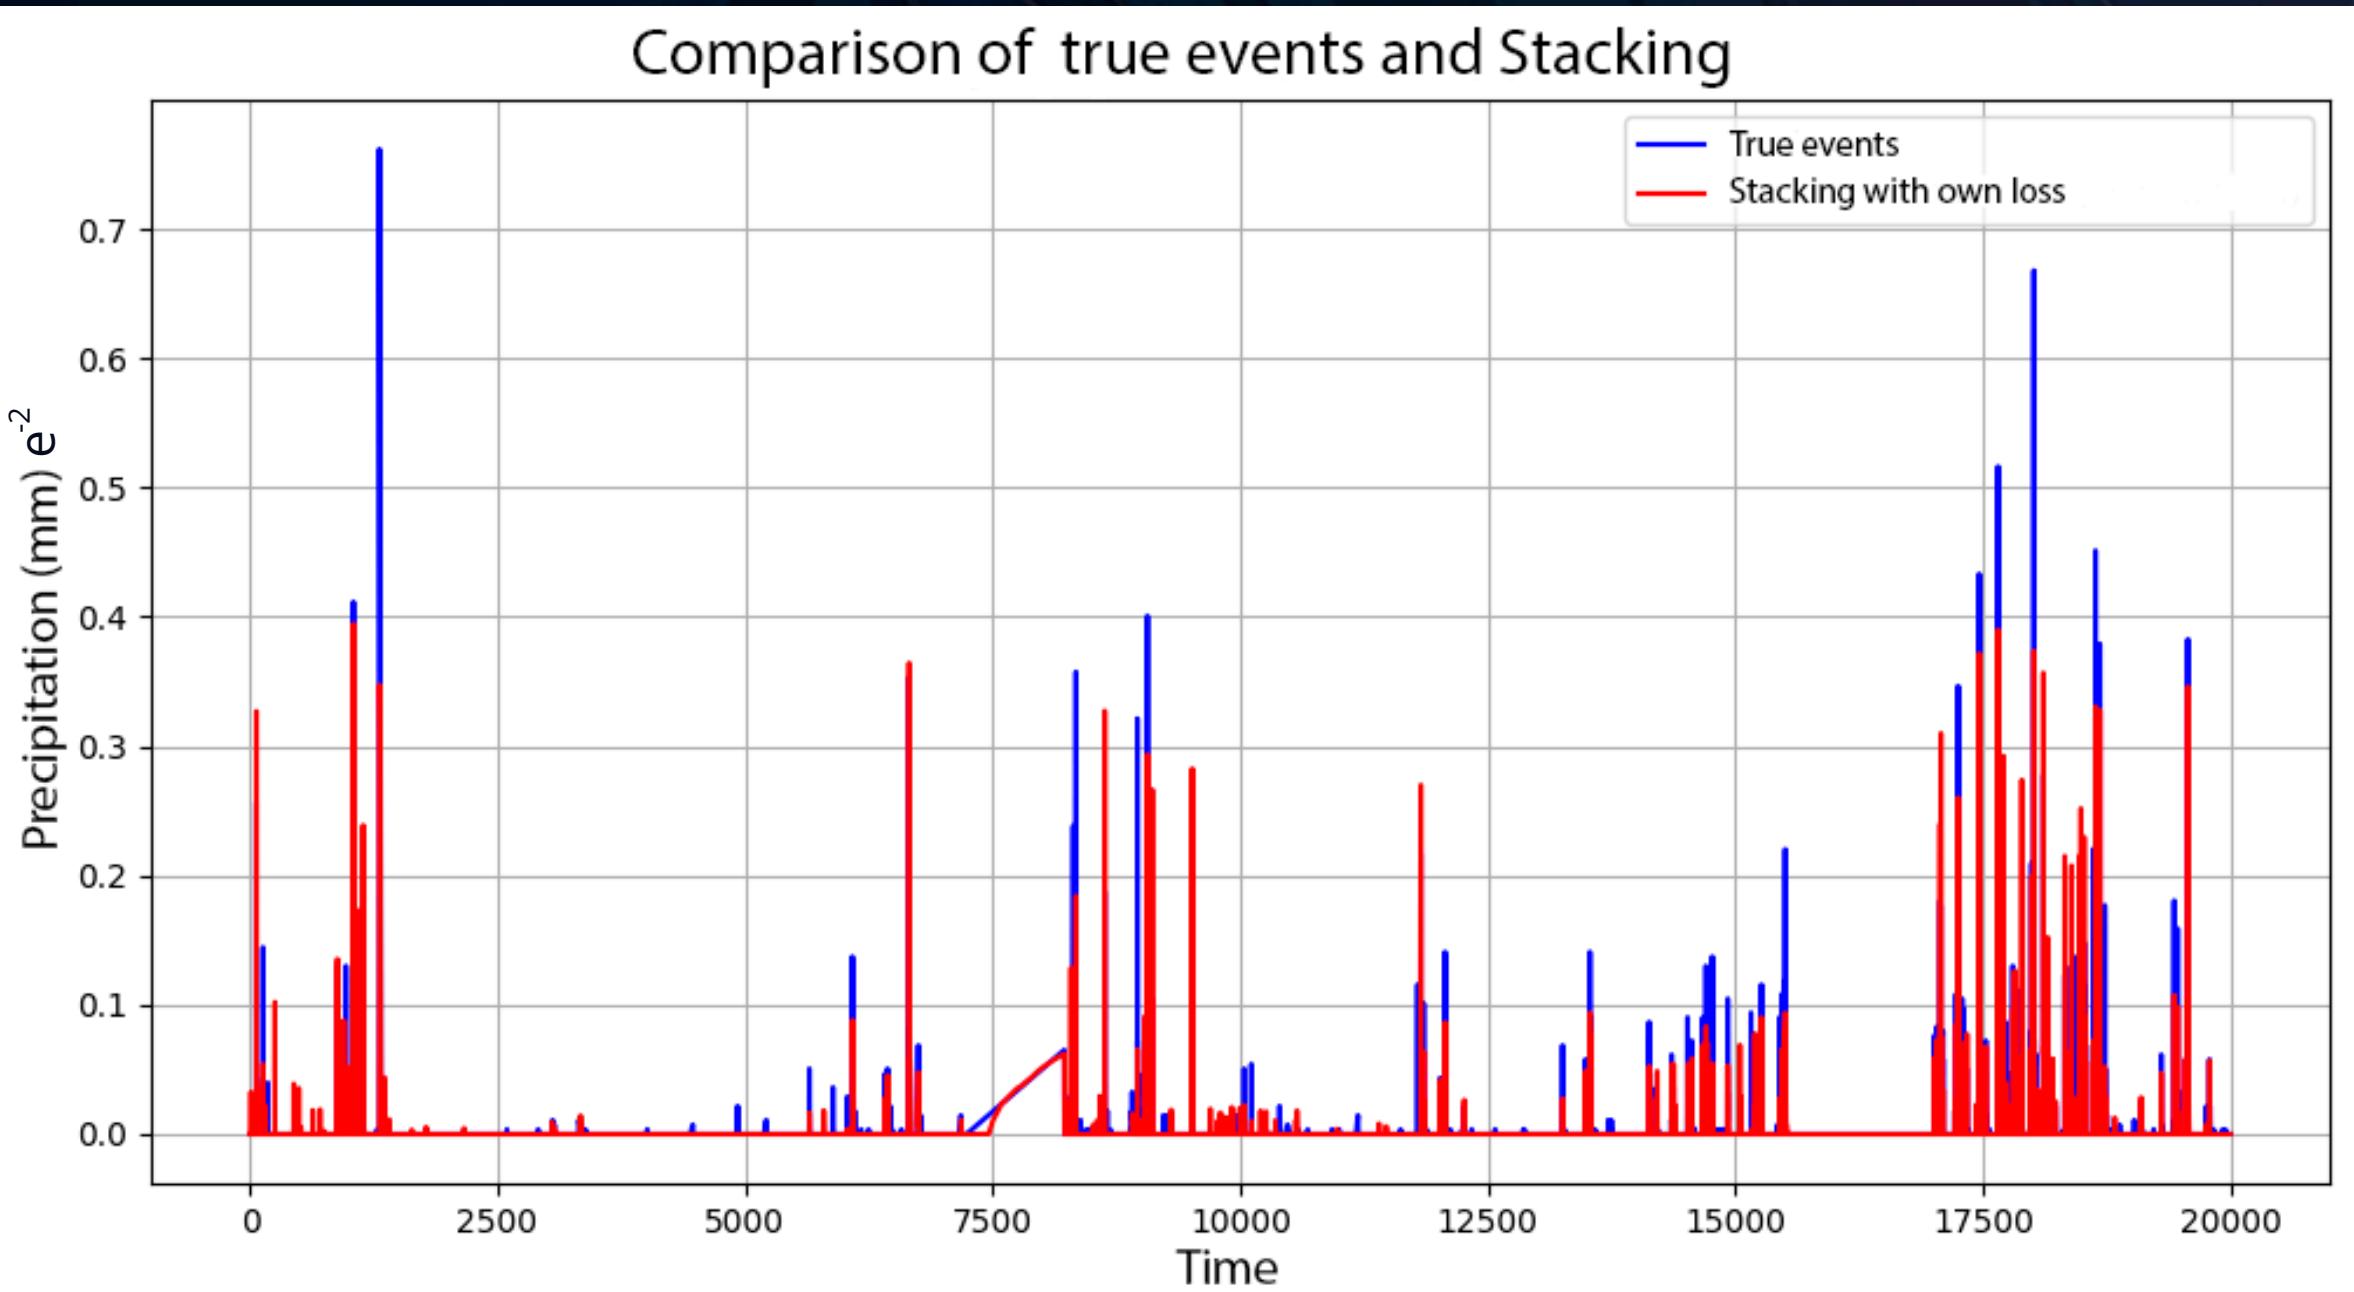
E os resultados disso?



E os resultados disso?



Loss +
stacking



Vamos entender em números:

Vamos classificar chuvas

Rain Class	Range (mm)
☀️ No Rain	0 - 3
🌤️ Light	3 - 8
☁️ Moderate	8 - 20
🌧️ Intense	20 - 30
⚡️ Very Intense	30 - 40
⛈️ Extreme	> 40

Vamos entender em números:

Vamos classificar chuvas

Topology	Rain Type	Analysis					
		Hits	Miss	Fault	Hit (%)	Miss (%)	Fault (%)
GRU	No Rain	30472	0	0	100.00	0.00	0.00
	Light	437	311	154	48.45	34.48	17.07
	Moderate	14	76	28	11.86	64.41	23.73
	Intense	0	16	0	0.00	100.00	0.00
	Very Intense	0	9	0	0.00	100.00	0.00
	Extreme	0	7	0	0.00	100.00	0.00
LSTM	No Rain	30521	0	0	100.00	0.00	0.00
	Light	340	414	129	38.51	46.89	14.61
	Moderate	6	75	4	7.06	88.24	4.71
	Intense	0	17	0	0.00	100.00	0.00
	Very Intense	0	10	0	0.00	100.00	0.00
	Extreme	0	7	0	0.00	100.00	0.00

Vamos entender em números:

Vamos classificar chuvas

Topology	Rain Type	Analysis					
		Hits	Miss	Fault	Hit (%)	Miss (%)	Fault (%)
Bidirectional GRU	No Rain	30382	0	0	100.00	0.00	0.00
	Light	619	129	251	61.96	12.91	25.13
	Moderate	11	71	21	10.68	68.93	20.39
	Intense	0	16	0	0.00	100.00	0.00
	Very Intense	0	9	0	0.00	100.00	0.00
	Extreme	0	8	0	0.00	100.00	0.00
Bidirectional LSTM	No Rain	30539	0	0	100.00	0.00	0.00
	Light	278	467	82	33.62	56.47	9.92
	Moderate	14	81	33	10.94	63.28	25.78
	Intense	0	19	0	0.00	100.00	0.00
	Very Intense	0	13	0	0.00	100.00	0.00
	Extreme	0	8	0	0.00	100.00	0.00

Vamos entender em números:

Vamos classificar chuvas

Topology	Rain Type	Analysis					
		Hits	Miss	Fault	Hit (%)	Miss (%)	Fault (%)
Stacking	No Rain	30563	0	0	100.00	0.00	0.00
	Light	578	154	129	67.13	17.89	14.98
	Moderate	11	72	17	11.00	72.00	17.00
	Intense	2	15	10	7.41	55.56	37.04
	Very Intense	2	9	13	8.33	37.50	54.17
	Extreme	7	7	10	29.17	29.17	41.67

Por que é tão difícil ?



1. Raridade dos Eventos



2. Alta Variabilidade e Ruído



3. Funções de custo e otimizadores normais procuram estabilidade e não outliers

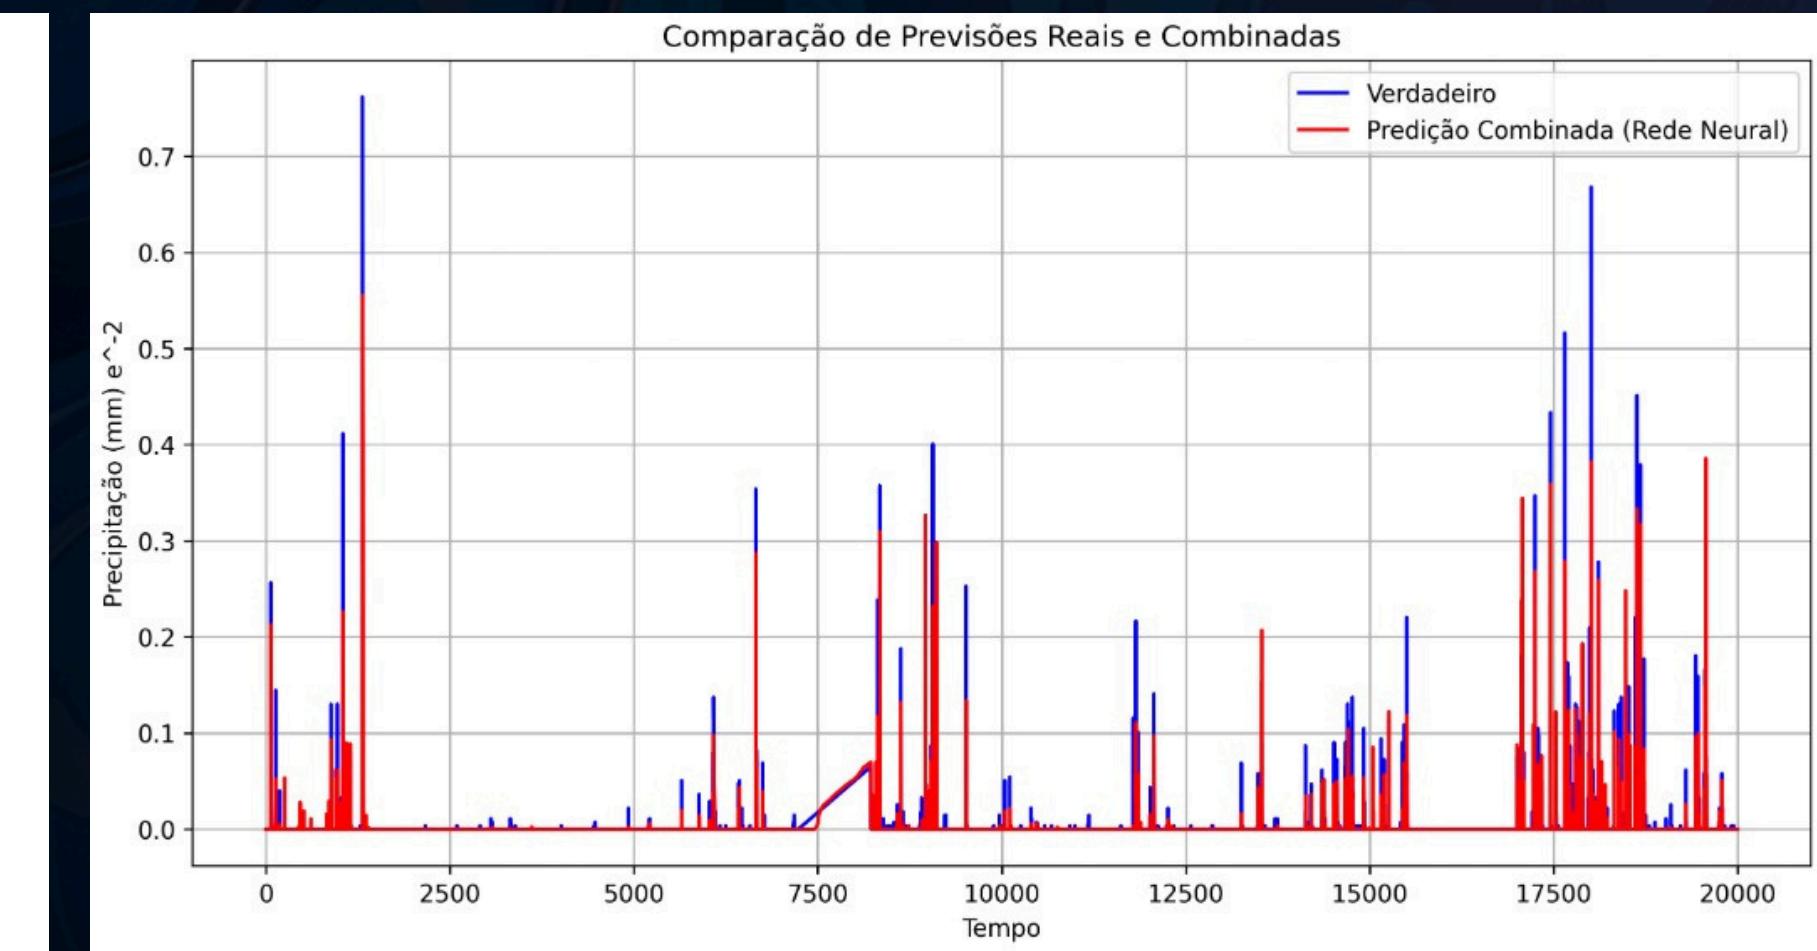
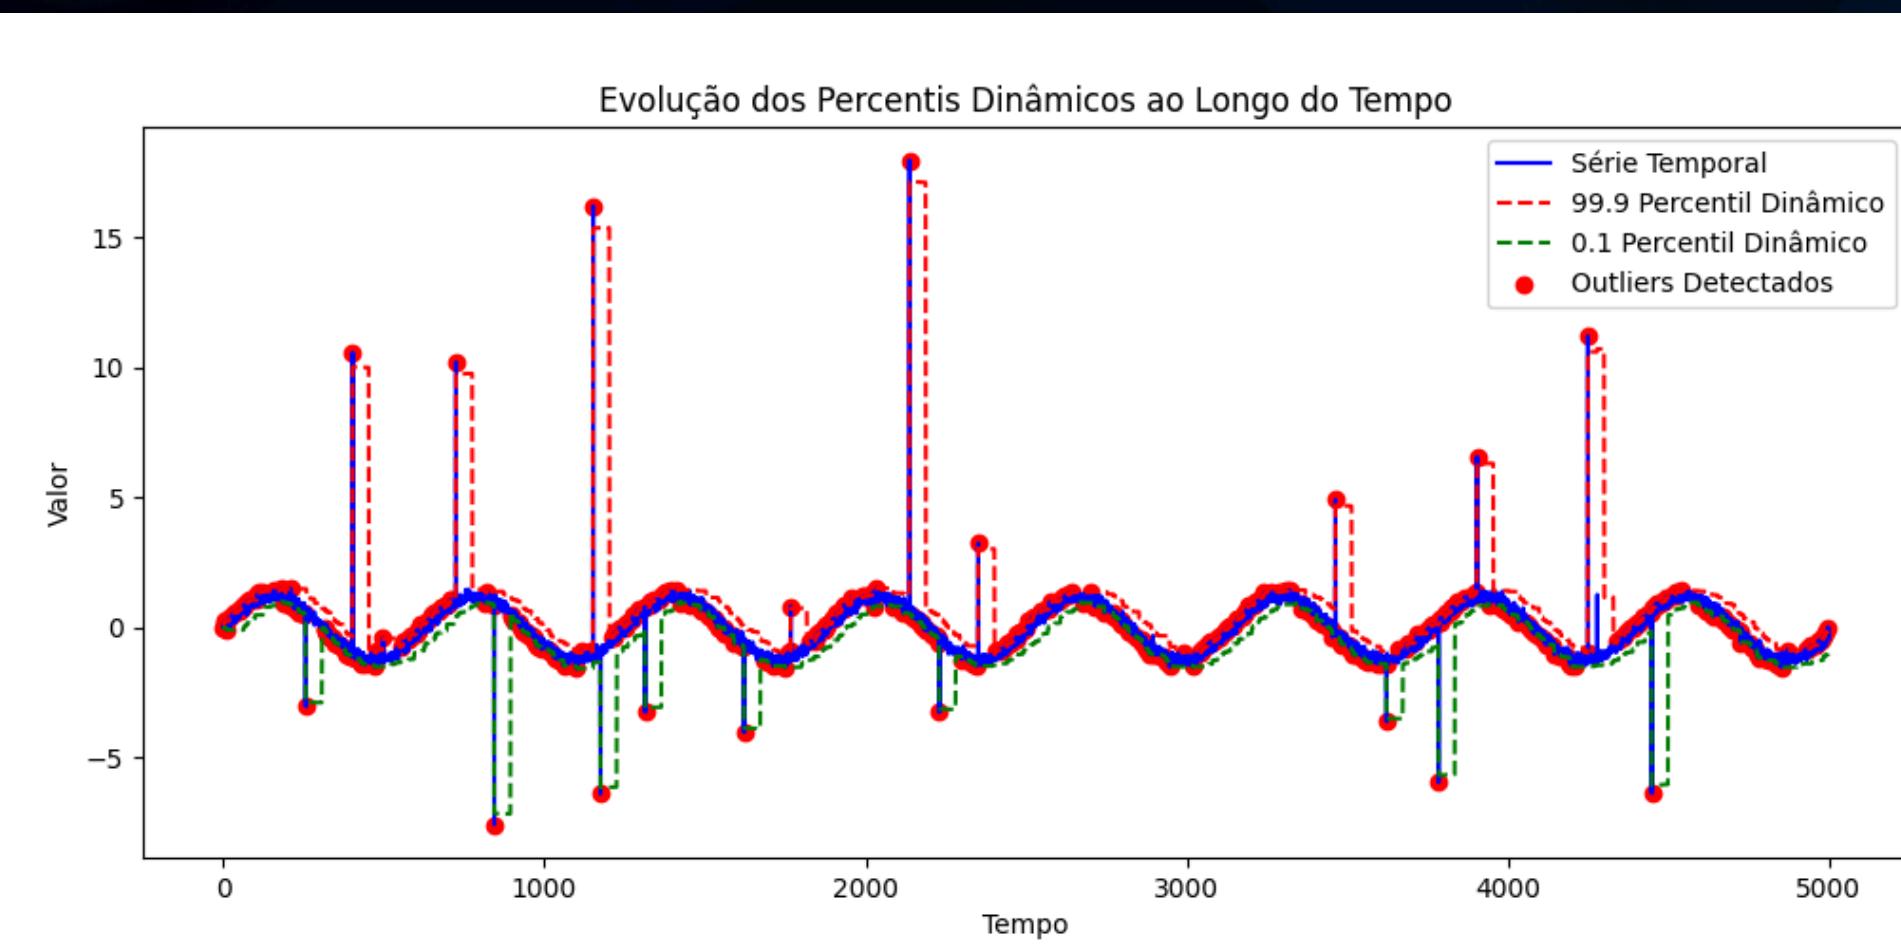


4. No caso da chuva há muitos zeros no target

Próximos trabalhos

nova custom loss

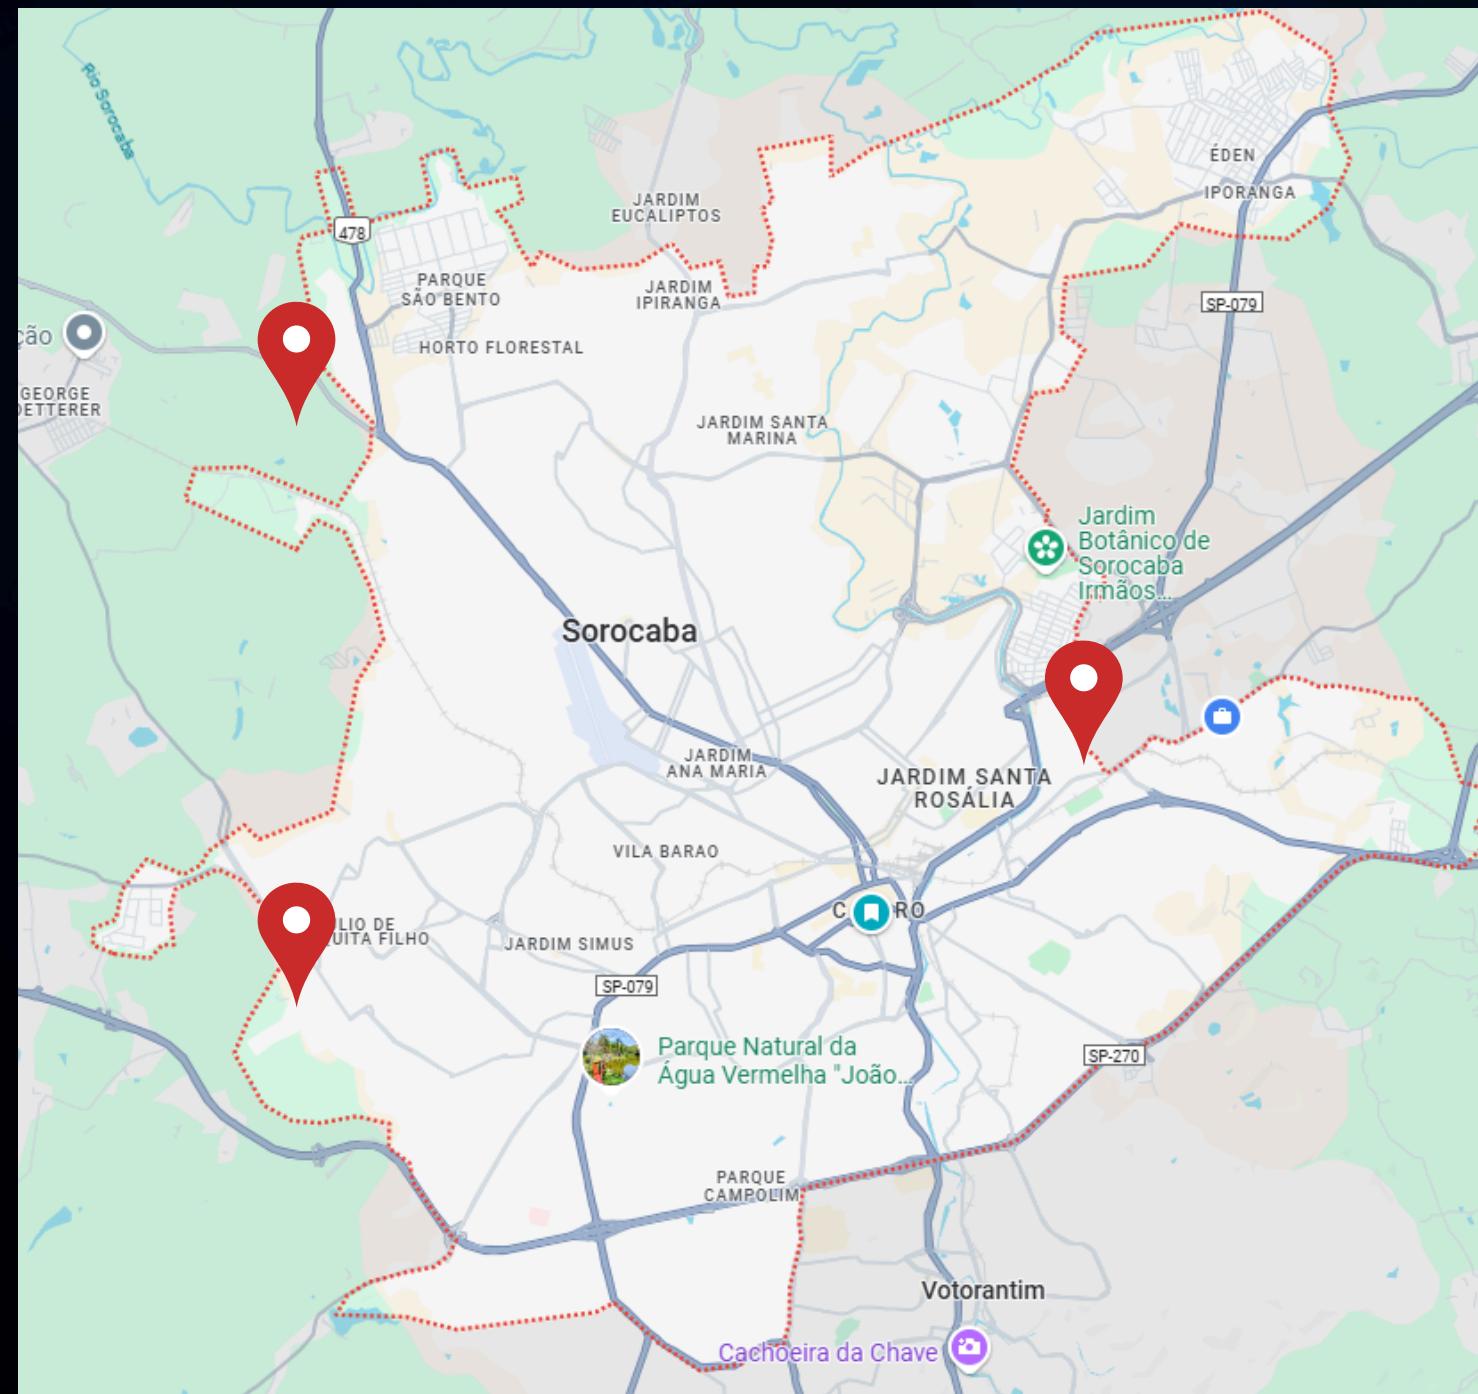
42% de acurácia em eventos extremos
em 48 horas antes



Threshold adaptativo
alpha adaptativo
amortecimento (evitar faults)

Próximos trabalhos

Predição de eventos extremos para locais ou series variadas



Próximos trabalhos

Otimizador

Otimizadores são como um personal

Ele analisa os erros (função de custo)
e ajusta os músculos certos (os pesos)
para melhorar o desempenho a cada
repetição (época).



Próximos trabalhos

Otimizador LORO



Próximos
Pesos e bias

$$\theta_{t+1} = \theta_t - n_t \times \text{penalty}_t \times \frac{gt}{\sqrt{E[g^2]}_t + \epsilon}$$

↑
Atual
Pesos e bias

learning rate

Outlier-aware

Gradiente

$$gt$$

↑
RMSPROP

$$\sqrt{E[g^2]}_t + \epsilon$$

Obrigado!